

Fundamentos de estadística descriptiva

El lenguaje básico para leer datos

Módulo: Módulo 1: Explorar (Fundamentos y Consulta de Datos)


Semana 1 · Clase 2 · Sep 8 al 13 · Virtual

Docente: Cristian A. Jimenez C., MSc — Sep 8 al 13


Hora 1	Hora 2	Hora 3
Variables, población/muestra y frecuencias	Tendencia central, dispersión, percentiles e interpretación	Laboratorio con un dataset real

En la Clase 1 vimos la pirámide **Datos → Información → Conocimiento → Sabiduría**. Hoy aprendemos las herramientas para dar ese primer salto: de datos sueltos a información resumida y confiable.

Cualitativas (describen una cualidad) vs. **cuantitativas** (se pueden medir o contar) — saber el tipo de variable define qué estadísticos y qué gráficos tienen sentido usar con ella (Semana 6, Principios de visualización).



Población: todos los casos posibles (todos los clientes, todas las transacciones). **Muestra:** el subconjunto que realmente observamos — casi nunca trabajamos con toda la población, por eso importa que la muestra sea representativa.



Muestra: subconjunto elegido para estudiar y generalizar (con cuidado) a toda la población

- ▶ **Frecuencia absoluta:** cuántas veces aparece cada valor.
- ▶ **Frecuencia relativa:** qué porcentaje representa.
- ▶ Es el primer paso para entender cualquier variable categórica.


Ejemplo real (dataset `tips`, día de la visita):

Día	Frec. absoluta	Frec. relativa
Sábado	87	35.7 %
Domingo	76	31.1 %
Jueves	62	25.4 %
Viernes	19	7.8 %

- ▶ **Media:** el promedio — suma de todos los valores dividida entre el número de datos.
- ▶ **Mediana:** el valor que queda justo en la mitad al ordenar los datos.
- ▶ **Moda:** el valor que más se repite (la única que aplica también a variables cualitativas).

¿Media o mediana?

Si hay valores extremos (atípicos), la media se **deja arrastrar** por ellos y deja de representar bien al conjunto — ahí la mediana es más confiable.




La distribución de la cuenta total en tips está sesgada a la derecha (pocas cuentas muy altas): por eso la media (19.8) queda **por encima** de la mediana (17.8).

- ▶ **Rango:** diferencia entre el valor máximo y el mínimo — muy sensible a atípicos.
- ▶ **Varianza:** qué tan lejos están, en promedio, los datos de la media (en unidades al cuadrado).
- ▶ **Desviación estándar:** la raíz de la varianza — vuelve a las unidades originales, más fácil de interpretar.

Ejemplo real


En tips, la cuenta total tiene desviación estándar $\approx 8,9$ USD alrededor de una media de 19.8 USD: las cuentas varían bastante de una mesa a otra.



El percentil 25 (P25) y el 75 (P75) forman el **rango intercuartílico (IQR)**: la “caja” donde vive el 50 % central de los datos. Los puntos naranjas son **valores atípicos** – muy por encima del resto.

Mide qué tan “torcida” está una distribución respecto a la simétrica (asimetría ≈ 0). Se calcula con el promedio de los desvíos a la media **elevados al cubo** (para que el signo indique el lado de la cola), dividido por la desviación estándar al cubo:


$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$



Asimetría positiva: la cola larga apunta a la derecha (la media queda por encima de la

Mide qué tan “apuntada” es una distribución y qué tan pesadas son sus colas, comparada con la normal (curtosis en exceso ≈ 0). Es el mismo tipo de cálculo que la asimetría, pero elevando los desvíos a la **cuarta potencia** y restando 3 (el valor de referencia de la normal):

$$g_2 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} - 3$$



Curtosis alta (leptocúrtica) → más valores extremos de lo esperado: revisa con cuidado los


Correlación: ¿cómo se relacionan dos variables?

Semana 1 • Clase 2

El coeficiente de correlación de Pearson (r) va de -1 a $+1$ y mide qué tan **lineal** es la relación entre dos variables x y y :

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Fuerte positiva
 $r = +0.92$




Moderada positiva
 $r = +0.40$



Prácticamente nula
 $r = +0.06$




Fuerte negativa
 $r = -0.91$



r **positivo**: relación **directa** — cuando una variable sube, la otra tiende a subir también.

r **negativo**: relación **inversa** — cuando una sube, la otra tiende a bajar. El **signo** indica la dirección; el **valor absoluto**, qué tan fuerte



A la izquierda hay una relación **perfectamente determinada** (una parábola) y aun así $r \approx 0$: Pearson no la detecta porque no es una línea recta. Antes de concluir “no hay relación”, **mira siempre el gráfico de dispersión**, no solo el número.

- ▶ Un solo número (la media, por ejemplo) **nunca cuenta toda la historia** — siempre revisa también la dispersión y la forma de la distribución.
- ▶ Un valor atípico no siempre es un error: puede ser información valiosa (una venta excepcional, un cliente distinto).
- ▶ Con muestras pequeñas, un estadístico puede variar mucho — no generalices de más.

Regla de oro (otra vez)

Antes de decidir con un número, mira siempre el conjunto de datos completo detrás de él.

Objetivo

- ▶ Calcular los estadísticos de hoy sobre un **dataset real** (tips: cuentas de un restaurante).
- ▶ Interpretar cada estadístico en palabras, no solo calcularlo.
- ▶ Detectar de forma inicial posibles valores atípicos.

Cuaderno

```
notebooks/  
lab-estadistica-  
descriptiva.ipynb
```

Trabajo individual o en parejas. El docente circula resolviendo dudas.

- ▶ Próxima sesión: **Python para análisis de datos: fundamentos** (Semana 2, virtual) — empezamos a programar.
- ▶ Guarda tus interpretaciones de hoy: son la primera evidencia cuantitativa de tu proyecto integrador.
- ▶ Dudas y comentarios.

¡Gracias!