

Fundamentos de estadística descriptiva

El lenguaje básico para leer datos

Módulo: Módulo 1: Explorar (Fundamentos y Consulta de Datos)


Semana 1 · Clase 2 · Sep 8 al 13 · Virtual

Docente: Cristian A. Jimenez C., MSc — Sep 8 al 13


Hora 1	Hora 2	Hora 3
Variables, población/muestra y frecuencias	Tendencia central, dispersión, percentiles e interpretación	Laboratorio con un dataset real

En la Clase 1 vimos la pirámide **Datos → Información → Conocimiento → Sabiduría**. Hoy aprendemos las herramientas para dar ese primer salto: de datos sueltos a información resumida y confiable.

- ▶ **Cualitativas:** describen una cualidad o categoría.
- ▶ **Cuantitativas:** se pueden medir o contar.
- ▶ Saber el tipo de variable define **qué estadísticos y qué gráficos** tienen sentido usar con ella (lo veremos en la Semana 6, Principios de visualización).



- ▶ **Población:** todos los casos posibles (todos los clientes, todas las transacciones).
- ▶ **Muestra:** el subconjunto que realmente observamos y analizamos.
- ▶ Casi nunca trabajamos con toda la población — por eso importa que la muestra sea representativa.



Muestra: subconjunto elegido para estudiar y generalizar (con cuidado) a toda la población

- ▶ **Frecuencia absoluta:** cuántas veces aparece cada valor.
- ▶ **Frecuencia relativa:** qué porcentaje representa.
- ▶ Es el primer paso para entender cualquier variable categórica.


Ejemplo real (dataset `tips`, día de la visita):

Día	Frec. absoluta	Frec. relativa
Sábado	87	35.7 %
Domingo	76	31.1 %
Jueves	62	25.4 %
Viernes	19	7.8 %

- ▶ **Media:** el promedio — suma de todos los valores dividida entre el número de datos.
- ▶ **Mediana:** el valor que queda justo en la mitad al ordenar los datos.
- ▶ **Moda:** el valor que más se repite (la única que aplica también a variables cualitativas).

¿Media o mediana?

Si hay valores extremos (atípicos), la media se **deja arrastrar** por ellos y deja de representar bien al conjunto — ahí la mediana es más confiable.




La distribución de la cuenta total en tips está sesgada a la derecha (pocas cuentas muy altas): por eso la media (19.8) queda **por encima** de la mediana (17.8).

- ▶ **Rango:** diferencia entre el valor máximo y el mínimo — muy sensible a atípicos.
- ▶ **Varianza:** qué tan lejos están, en promedio, los datos de la media (en unidades al cuadrado).
- ▶ **Desviación estándar:** la raíz de la varianza — vuelve a las unidades originales, más fácil de interpretar.

Ejemplo real

En tips, la cuenta total tiene desviación estándar $\approx 8,9$ USD alrededor de una media de 19.8 USD: las cuentas varían bastante de una mesa a otra.



El percentil 25 (P25) y el 75 (P75) forman el **rango intercuartílico (IQR)**: la “caja” donde vive el 50 % central de los datos. Los puntos naranjas son **valores atípicos** – muy por encima del resto.

- ▶ Un solo número (la media, por ejemplo) **nunca cuenta toda la historia** — siempre revisa también la dispersión y la forma de la distribución.
- ▶ Un valor atípico no siempre es un error: puede ser información valiosa (una venta excepcional, un cliente distinto).
- ▶ Con muestras pequeñas, un estadístico puede variar mucho — no generalices de más.

Regla de oro (otra vez)

Antes de decidir con un número, mira siempre el conjunto de datos completo detrás de él.

Objetivo

- ▶ Calcular los estadísticos de hoy sobre un **dataset real** (tips: cuentas de un restaurante).
- ▶ Interpretar cada estadístico en palabras, no solo calcularlo.
- ▶ Detectar de forma inicial posibles valores atípicos.

Cuaderno

```
notebooks/  
lab-estadistica-  
descriptiva.ipynb
```

Trabajo individual o en parejas. El docente circula resolviendo dudas.

- ▶ Próxima sesión: **Python para análisis de datos: fundamentos** (Semana 2, virtual) — empezamos a programar.
- ▶ Guarda tus interpretaciones de hoy: son la primera evidencia cuantitativa de tu proyecto integrador.
- ▶ Dudas y comentarios.

¡Gracias!