

Fundamentos de estadística descriptiva

El lenguaje básico para leer datos

Módulo: Módulo 1: Explorar (Fundamentos y Consulta de Datos)


Semana 1 · Clase 2 · Sep 8 al 13 · Virtual

Docente: Cristian A. Jimenez C., MSc — Sep 8 al 13

Hora 1	Hora 2	Hora 3
Variables, población/muestra y frecuencias	Tendencia central, dispersión, percentiles e interpretación	Laboratorio con un dataset real

En la Clase 1 vimos la pirámide **Datos → Información → Conocimiento → Sabiduría**. Hoy aprendemos las herramientas para dar ese primer salto: de datos sueltos a información resumida y confiable.

Cualitativas (describen una cualidad) vs. **cuantitativas** (se pueden medir o contar) — saber el tipo de variable define qué estadísticos y qué gráficos tienen sentido usar con ella (Semana 6, Principios de visualización).



Nominal — categorías **sin orden** lógico entre ellas:

- ▶ **Color de ojos:** café, azul, verde — ninguno es “más” que otro.
- ▶ **Marca de celular:** Samsung, iPhone, Xiaomi.
- ▶ **Ciudad de residencia:** Medellín, Bogotá, Cali.

Ordinal — categorías **con orden**, pero sin una distancia numérica clara entre ellas:

- ▶ **Estrato socioeconómico:** 1, 2, 3 ...6 — hay orden, pero el salto de 1 a 2 no es “igual” al de 5 a 6.
- ▶ **Nivel de satisfacción:** malo < regular < bueno < excelente.
- ▶ **Nivel educativo:** primaria < bachillerato < pregrado < posgrado.


Discreta — se **cuenta**, solo toma valores enteros (no existe “2.5 hermanos”):

- ▶ **Número de hermanos:** 0, 1, 2, 3...
- ▶ **Número de correos recibidos hoy.**
- ▶ **Número de productos en una factura.**

Continua — se **mide**, puede tomar cualquier valor dentro de un rango (con decimales):

- ▶ **Estatura:** 1.68 m, 1.685 m... (siempre cabe un decimal más).
- ▶ **Peso corporal.**
- ▶ **Tiempo de entrega de un pedido** (en minutos).

Población: todos los casos posibles (todos los clientes, todas las transacciones). **Muestra:** el subconjunto que realmente observamos. Casi nunca trabajamos con toda la población, por eso importa que la muestra sea representativa.



Ejemplo

Una tienda tiene 5,000 clientes registrados (**población**). Para saber qué tan satisfechos están, no se llama a los 5,000: se elige al azar una **muestra** de 200 y se les pregunta a ellos. Si esos 200 se eligieron bien (al azar, sin sesgo), su respuesta permite estimar razonablemente lo que opinan los 5,000.

- ▶ **Frecuencia absoluta:** cuántas veces aparece cada valor.
- ▶ **Frecuencia relativa:** qué porcentaje representa.
- ▶ Es el primer paso para entender cualquier variable categórica.

Ejemplo real (dataset `tips`, día de la visita):

Día	Frec. absoluta	Frec. relativa
Sábado	87	35.7 %
Domingo	76	31.1 %
Jueves	62	25.4 %
Viernes	19	7.8 %

Un solo número que resume “dónde está el centro” de los datos. Hay tres, y cada una responde una pregunta distinta:

- ▶ **Media:** el promedio.
- ▶ **Mediana:** el valor central al ordenar los datos.
- ▶ **Moda:** el valor que más se repite.

Vamos una por una, calculándolas a mano sobre datos reales de `tips` (cuentas de restaurante).

Se suman todos los valores y se dividen entre cuántos son:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Paso a paso, con 5 cuentas reales de tips (USD)

Datos: 10,07, 15,98, 16,66, 17,29, 19,44

$$\bar{x} = \frac{10,07 + 15,98 + 16,66 + 17,29 + 19,44}{5} = \frac{79,44}{5} = 15,89$$

A escala completa: con las 244 cuentas de tips, la media de `total_bill` es **19.79 USD**.

Se ordenan los datos de menor a mayor. Si n es **impar**, la mediana es el valor de la mitad; si n es **par**, es el promedio de los dos valores centrales.

Mismos 5 datos, ya ordenados

10,07, 15,98, **16,66**, 17,29, 19,44 ($n = 5$, impar)


mediana = 16,66

A escala completa: con $n = 244$ (par), la mediana es el promedio de las cuentas en las posiciones 122 y 123 (17.78 y 17.81): **17.79 USD**.

¿Por qué a veces preferimos la mediana?


Si la cuenta más alta del ejemplo (19.44) fuera en realidad 190.00, la media se dispararía a 50.00, pero la mediana **seguiría siendo 16.66**: es mucho más resistente a valores atípicos.

Es el valor (o categoría) que más veces aparece. Es la **única** medida de tendencia central que también sirve para variables cualitativas.



Cuantitativa: el tamaño de grupo más común en tips es **2 personas** (156 de 244 cuentas, 64 %).

Cualitativa: el día con más cuentas registradas es **sábado** (87 de 244, 36 %), viendo la sección 2 de frecuencias.



La distribución de la cuenta total en tips está sesgada a la derecha (pocas cuentas muy altas): por eso la media (19.8) queda **por encima** de la mediana (17.8).

La tendencia central dice dónde está el centro, pero no qué tan “dispersos” o “apretados” están los datos alrededor de él. Para eso usamos:

- ▶ **Rango:** diferencia entre el valor máximo y el mínimo.
- ▶ **Varianza:** qué tan lejos están, en promedio, los datos de la media.
- ▶ **Desviación estándar:** la raíz de la varianza, en las unidades originales.

Otra vez, una por una, con los mismos 5 datos de `tips` usados para media y mediana.

Es la diferencia entre el valor más grande y el más pequeño:

$$R = x_{\text{máx}} - x_{\text{mín}}$$

Paso a paso, con los mismos 5 datos

Datos: 10,07, 15,98, 16,66, 17,29, 19,44

$$R = 19,44 - 10,07 = 9,37 \text{ USD}$$

A escala completa: en las 244 cuentas de tips, el rango es $50,81 - 3,07 = 47,74 \text{ USD}$.

Cuidado

El rango solo mira los dos extremos: un único valor atípico (muy alto o muy bajo) lo dispara, aunque el resto de los datos esté muy junto.

Se promedian los cuadrados de las distancias de cada dato a la media. Se eleva al cuadrado para que las distancias negativas y positivas no se cancelen. Cuando los datos son una **muestra**, se divide entre $n - 1$ (no entre n):

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Paso a paso, con los mismos 5 datos ($\bar{x} = 15,89$)

Desvíos: $-5,82, 0,09, 0,77, 1,40, 3,55$ Al cuadrado: $33,85, 0,01, 0,60, 1,97, 12,62$

$$s^2 = \frac{33,85 + 0,01 + 0,60 + 1,97 + 12,62}{5 - 1} = \frac{49,04}{4} = 12,26 \text{ USD}^2$$

A escala completa: con las 244 cuentas, $s^2 = 79,25 \text{ USD}^2$ (difícil de interpretar en USD al cuadrado, por eso casi nunca se usa sola).

Es simplemente la raíz cuadrada de la varianza, para volver a las unidades del dato original (USD, no USD²):

$$s = \sqrt{s^2}$$


Mismos 5 datos

$$s = \sqrt{12,26} = 3,50 \text{ USD}$$

A escala completa: con las 244 cuentas de tips, $s = \sqrt{79,25} = 8,90 \text{ USD}$.

Ejemplo real


La cuenta total tiene desviación estándar $\approx 8,9 \text{ USD}$ alrededor de una media de 19.8 USD: las cuentas varían bastante de una mesa a otra.



El percentil 25 (P25) y el 75 (P75) forman el **rango intercuartílico (IQR)**: la “caja” donde vive el 50 % central de los datos. Los puntos naranjas son **valores atípicos** – muy por encima del resto.

Mide qué tan “torcida” está una distribución respecto a la simétrica (asimetría ≈ 0). Se calcula con el promedio de los desvíos a la media **elevados al cubo** (para que el signo indique el lado de la cola), dividido por la desviación estándar al cubo:


$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{s^3}$$



Asimetría positiva: la cola larga apunta a la derecha (la media queda por encima de la

Mide qué tan “apuntada” es una distribución y qué tan pesadas son sus colas, comparada con la normal (curtosis en exceso ≈ 0). Es el mismo tipo de cálculo que la asimetría, pero elevando los desvíos a la **cuarta potencia** y restando 3 (el valor de referencia de la normal):

$$g_2 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^4}{s^4} - 3$$



Curtosis alta (leptocúrtica) → más valores extremos de lo esperado: revisa con cuidado los


Correlación: ¿cómo se relacionan dos variables?

Semana 1 • Clase 2

El coeficiente de correlación de Pearson (r) va de -1 a $+1$ y mide qué tan **lineal** es la relación entre dos variables x y y :

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Fuerte positiva
 $r = +0.92$




Moderada positiva
 $r = +0.40$



Prácticamente nula
 $r = +0.06$



Fuerte negativa
 $r = -0.91$



r **positivo**: relación **directa** — cuando una variable sube, la otra tiende a subir también.

r **negativo**: relación **inversa** — cuando una sube, la otra tiende a bajar. El **signo** indica la dirección; el **valor absoluto**, qué tan fuerte

Relación cuadrática
 $r = -0.04$ (¡casi nula!)



Relación logarítmica
 $r = 0.88$ (alto, pero no es recta)



A la izquierda hay una relación **perfectamente determinada** (una parábola) y aun así $r \approx 0$: Pearson no la detecta porque no es una línea recta. Antes de concluir “no hay relación”, **mira siempre el gráfico de dispersión**, no solo el número.

- ▶ Un solo número (la media, por ejemplo) **nunca cuenta toda la historia** — siempre revisa también la dispersión y la forma de la distribución.
- ▶ Un valor atípico no siempre es un error: puede ser información valiosa (una venta excepcional, un cliente distinto).
- ▶ Con muestras pequeñas, un estadístico puede variar mucho — no generalices de más.

Regla de oro (otra vez)

Antes de decidir con un número, mira siempre el conjunto de datos completo detrás de él.

Objetivo

- ▶ Identificar el **tipo de cada variable** de un dataset (viviendas: 18 apartamentos y casas de Medellín).
- ▶ Decidir **qué estadísticos tienen sentido** para cada variable, y cuáles no aunque sean numéricas.
- ▶ Calcular e interpretar esos estadísticos, y detectar valores atípicos.

Cuaderno

```
notebooks/  
taller-tipos-  
de-variable.ipynb
```

Trabajo individual o en parejas. El docente circula resolviendo dudas.

Si quieres repasar o ir más allá de lo visto hoy:

- ▶ Anderson, D. R., Sweeney, D. J., & Williams, T. A. *Estadística para administración y economía*. Cengage Learning. (El libro de estadística más usado en programas de administración en Latinoamérica; en español.)
- ▶ Wheelan, C. (2013). *Naked Statistics: Stripping the Dread from the Data*. W. W. Norton & Company. (Explica las mismas ideas de hoy con ejemplos cotidianos, sin fórmulas pesadas; en inglés.)
- ▶ Diez, D., Barr, C., & Çetinkaya-Rundel, M. *OpenIntro Statistics*. Libro de texto **gratuito**, usado en universidades como Duke y Princeton.

Página web

<https://www.openintro.org/book/os/> PDF descargable gratis, con datos reales y ejercicios (en inglés).

- ▶ Próxima sesión: **Python para análisis de datos: fundamentos** (Semana 2, virtual) — empezamos a programar.
- ▶ Guarda tus interpretaciones de hoy: son la primera evidencia cuantitativa de tu proyecto integrador.
- ▶ Dudas y comentarios.

¡Gracias!