

Instrucciones generales: trabaja individualmente o en parejas. Puedes usar calculadora, Excel o el método que prefieras para los cálculos; lo importante es que **muestres el procedimiento**, no solo el resultado. El docente circula resolviendo dudas durante la hora.

Objetivo de esta hora:

1. Identificar el **tipo de cada variable** de un conjunto de datos.
2. Decidir, para cada variable, **qué estadísticos tienen sentido** calcular (y cuáles no, aunque la variable sea numérica).
3. Calcular e interpretar esos estadísticos, y detectar valores atípicos.

El dataset: viviendas.csv, 18 viviendas (apartamentos y casas) del área metropolitana de Medellín. **Son datos inventados con fines didácticos**, no corresponden a inmuebles reales. La tabla completa está en la página siguiente (orientación horizontal) para que la tengas de referencia durante todo el taller.

id_vivienda	identificador único de la vivienda
tipo	Apartamento o Casa
barrio	barrio donde está ubicada
estrato	estrato socioeconómico (1 a 6)
area_m2	área construida, en m ²
habitaciones / banos / parqueaderos	cantidades
antigüedad_anios	antigüedad de la construcción, en años
estado	Malo, Regular, Bueno o Excelente
tiene_ascensor	si el edificio tiene ascensor (Sí/No)
precio_millones	precio de venta, en millones de COP

Dataset: viviendas.csv

id	tipo	barrio	estr.	área m ²	hab.	baños	parq.	años	estado	ascensor	precio (M COP)
V01	Apartamento	El Poblado	6	120	3	3	2	5	Excelente	Sí	850
V02	Casa	Belén	3	90	3	2	1	15	Bueno	No	320
V03	Apartamento	Laureles	4	70	2	2	1	10	Bueno	Sí	410
V04	Casa	Envigado	5	150	4	3	2	8	Excelente	No	690
V05	Apartamento	Robledo	2	55	2	1	0	20	Regular	No	150
V06	Casa	Sabaneta	4	110	3	2	2	12	Bueno	No	380
V07	Apartamento	El Poblado	6	95	2	2	2	3	Excelente	Sí	720
V08	Casa	Belén	3	80	3	2	1	25	Regular	No	260
V09	Apartamento	Laureles	4	65	2	1	1	18	Regular	Sí	300
V10	Casa	Itagüí	2	70	3	1	0	30	Malo	No	120
V11	Apartamento	Envigado	5	100	3	2	1	6	Bueno	Sí	520
V12	Casa	Robledo	2	60	2	1	0	22	Malo	No	95
V13	Apartamento	Sabaneta	4	75	2	2	1	9	Bueno	Sí	340
V14	Casa	El Poblado	6	200	4	4	3	4	Excelente	No	1400
V15	Apartamento	Belén	3	58	2	1	1	14	Regular	Sí	210
V16	Casa	Laureles	4	130	3	3	2	11	Bueno	No	480
V17	Apartamento	Itagüí	2	50	1	1	0	28	Malo	No	85
V18	Casa	Envigado	5	140	4	3	2	7	Excelente	No	650

1. Identifica el tipo de cada variable

Recuerda

Cualitativa nominal: categorías sin orden (colores, ciudades). **Cualitativa ordinal:** categorías **con** un orden natural (tallas, niveles de satisfacción). **Cuantitativa discreta:** se cuenta, valores enteros (número de hijos). **Cuantitativa continua:** se mide, puede tomar cualquier valor en un rango (estatura, peso).

Variable	Tipo de variable (tu respuesta)
id_vivienda	
tipo	
barrio	
estrato	
area_m2	
habitaciones	
banos	
parqueaderos	
antiguedad_anios	
estado	
tiene_ascensor	
precio_millones	

2. ¿Qué estadísticos tienen sentido para cada variable?

No todos los estadísticos aplican a todas las variables, **aunque la columna tenga números**. Regla general:

- Si es **cualitativa nominal**: solo tiene sentido la **moda** (y contar frecuencias). Media y mediana no significan nada (¿cuál sería el “barrio promedio”?).
- Si es **cualitativa ordinal**: tiene sentido la **moda** y, con cuidado, la **mediana** (hay un orden). La **media es discutible**: aunque estrato se vea como un número, la distancia entre estrato 1 y 2 no es necesariamente “igual” a la distancia entre estrato 5 y 6; calcular su promedio es una práctica común pero estadísticamente cuestionable.
- Si es **cuantitativa** (discreta o continua): media, mediana, moda, rango, varianza y desviación estándar tienen sentido.

Pregunta 1

Para cada una de estas 5 variables, responde: ¿tiene sentido calcular su **media**? ¿Por qué sí o por qué no?

Procedimiento y resultado

```
barrio:  
estrato:  
estado:  
area_m2:  
tiene_ascensor:
```

3. Frecuencias de las variables cualitativas

Para las variables donde la media no aplica, la **moda** y las **frecuencias** sí nos dicen algo útil. Usando la tabla de datos, cuenta cuántas viviendas hay de cada categoría.

Procedimiento y resultado

```
Tipo de vivienda (Apartamento / Casa):  
Barrio con más viviendas:  
Estado más frecuente:
```

4. Medidas de tendencia central

Calcula, sobre la columna `precio_millones` (las 18 viviendas): media, mediana y moda.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Procedimiento y resultado

Pregunta 2

La media, ¿queda por encima o por debajo de la mediana? Según lo visto en la Clase 2, ¿qué te dice eso sobre la forma de la distribución de `precio_millones`? (pista: revisa si hay una o dos viviendas mucho más caras que el resto).

Procedimiento y resultado

5. Medidas de dispersión

Calcula rango, varianza y desviación estándar de `precio_millones`.

$$R = x_{\text{máx}} - x_{\text{mín}} \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad s = \sqrt{s^2}$$

Procedimiento y resultado

Pregunta 3

La desviación estándar, ¿te parece “grande” comparada con la media? ¿Qué te dice eso sobre qué tan parecidas son las 18 viviendas entre sí en precio?

Procedimiento y resultado

6. Percentiles y detección de valores atípicos

Ordena las 18 viviendas por `precio_millones` y ubica P25 (el valor en la posición 25 % de los datos ordenados) y P75. Con eso calcula el rango intercuartílico (IQR) y el límite superior para atípicos:

$$\text{IQR} = P_{75} - P_{25} \quad \text{límite superior} = P_{75} + 1,5 \times \text{IQR}$$

Procedimiento y resultado

Pregunta 4

¿Qué vivienda(s) superan el límite superior? ¿Tienen algo en común (estrato, área, barrio) que explique el precio tan alto? Justifica tu respuesta con al menos un dato de la tabla.

Procedimiento y resultado

7. Curiosidad: ¿el precio cambia según el estrato?

El profesor ya calculó el precio promedio por estrato con todo el dataset:

Estrato	2	3	4	5	6
Precio promedio (M COP)	112.5	263.3	382.0	620.0	990.0

Pregunta 5

¿El precio promedio sube de forma consistente con el estrato? ¿Te parece razonable esa relación? ¿Por qué crees que pasa esto en la vida real?

Procedimiento y resultado

8. Reto final

Repita el análisis de las secciones 4 a 6 (tendencia central, dispersión y atípicos), pero ahora sobre la columna `area_m2` en lugar de `precio_millones`.

Procedimiento y resultado

Cierre. La idea que más importa hoy: **antes de calcular, pregunta si el cálculo tiene sentido para ese tipo de variable.** Un promedio mal aplicado (como el “barrio promedio”) es un error común en el análisis de datos real. Próxima sesión: **Python para análisis de datos: fundamentos**, empezamos a programar en serio.