Esumer
Educación Superior

Principios de visualización y comunicación de datos

De la tabla resumen al gráfico que convence

Módulo: Módulo 2: Construir (Limpieza y Gestión de Datos)

Semana 6 · Clase 11 · Oct 13 al 18 · Virtual

Docente: Cristian A. Jimenez C., MSc — Oct 13 al 18

Agenda de hoy (3 horas)

Hora 1	Hora 2	Hora 3
Qué hace efectiva una visualización y cómo elegir el gráfico según la pregunta	Escalas, etiquetas, color y reducción de ruido visual	Errores comunes y gráficos engañosos; taller en Google Colab

Desde la Clase 9 sabes construir un cuadro de indicadores con `groupby`. Hoy aprendes a mostrarlo: las mismas cifras, bien o mal presentadas, cambian lo que tu audiencia entiende y decide.

¿Qué hace efectiva una visualización?

Un gráfico es efectivo cuando tu audiencia entiende el mensaje **más rápido mirándolo que leyendo la tabla de números**. No es una decoración del resultado: es parte del análisis.

Tres preguntas antes de abrir cualquier librería de gráficos

1. ¿Qué **pregunta de negocio** estoy respondiendo?
2. ¿Qué tipo de comparación necesita esa pregunta? (Sección siguiente)
3. ¿Qué es lo **mínimo** que tengo que mostrar para que se entienda, sin nada de más?

Si no puedes nombrar la pregunta que responde tu gráfico, todavía no estás listo para hacerlo.

Las cuatro preguntas que determinan el gráfico

Casi cualquier gráfico de negocio responde una de estas cuatro preguntas. Identificarla primero evita el error más común: elegir el gráfico que se ve bonito en vez del que se entiende rápido.

¿Qué pregunta quieres responder?

Comparación	Composición	Distribución	Relación
¿Cómo se compara algo entre categorías o en el tiempo?	¿Cómo se reparte un total en sus partes?	¿Cómo se distribuyen los valores de una variable?	¿Cómo se relacionan dos variables entre sí?









Comparación

Pregunta: ¿cómo se compara algo entre categorías, o a lo largo del tiempo?

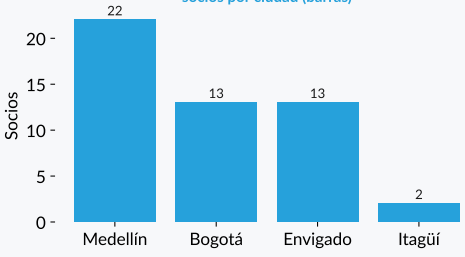
Pocas categorías, un momento	Evolución en el tiempo
Barras verticales u horizontales. Ejemplo: socios por ciudad (Clase 9).	Línea. Ejemplo: inscripciones por mes (Clase 9, `dt.to_period`).

Regla práctica: con más de 10 a 12 categorías, una tabla ordenada suele comunicar mejor que un gráfico de barras saturado.

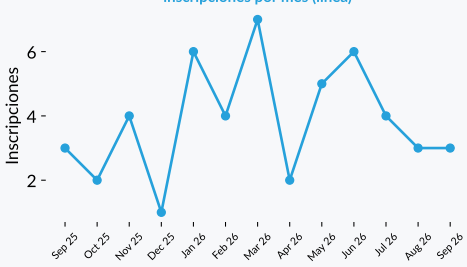
Comparación: ejemplos con nuestros datos

Comparación: dos formas de comparar

Pocas categorías, un momento: socios por ciudad (barras)



Evolución en el tiempo: inscripciones por mes (línea)



Composición

Pregunta: ¿cómo se reparte un total en sus partes?

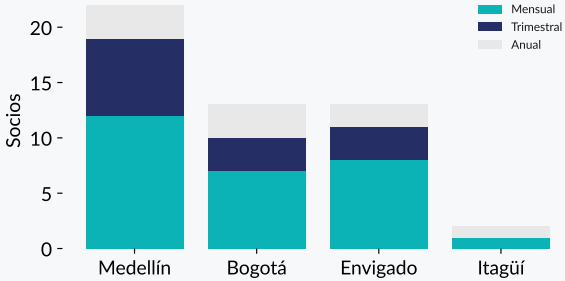
Una sola composición	Composición que cambia
Barras apiladas, o un gráfico de pastel **solo** si hay pocas categorías (3 a 5) y la diferencia entre ellas es clara.	Barras apiladas al 100 % por periodo, o varias barras apiladas una al lado de otra.

Ejemplo del curso: participación de cada plan dentro de cada ciudad (Clase 9, `.transform("sum")`).

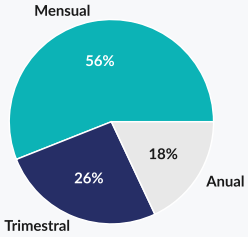
Composición: ejemplos con nuestros datos

Composición: dos formas de repartir un total

Composición que cambia:
plan por ciudad (barras apiladas)



Una sola composición:
plan del total de socios (pastel)



Distribución

Pregunta: ¿cómo se distribuyen los valores de una variable? ¿Dónde se concentran, qué tan dispersos están, hay valores atípicos?

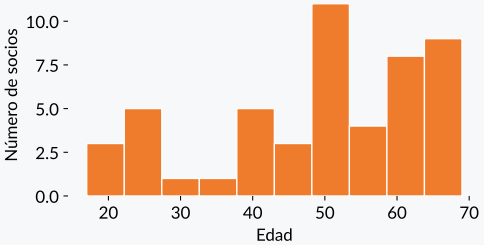
Una variable	Comparar distribuciones
Histograma (Clase 2): agrupa los valores en rangos y cuenta cuántas observaciones caen en cada uno.	Boxplot (Clase 2): resume mediana, cuartiles y valores atípicos; útil para comparar varios grupos a la vez.

Ejemplo del curso: la distribución de edades de los socios, o cómo se compara esa distribución entre planes.

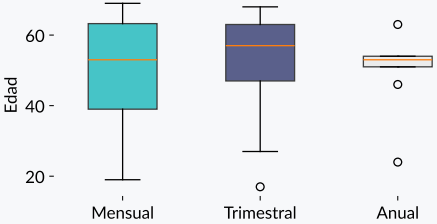
Distribución: ejemplos con nuestros datos

Distribución: dónde se concentran los valores

Una variable:
edad de los socios (histograma)



Comparar distribuciones:
edad por plan (boxplot)



Relación

Pregunta: ¿cómo se relacionan dos variables entre sí? ¿Cuando una sube, la otra sube, baja, o no cambia?

Dos variables numéricas

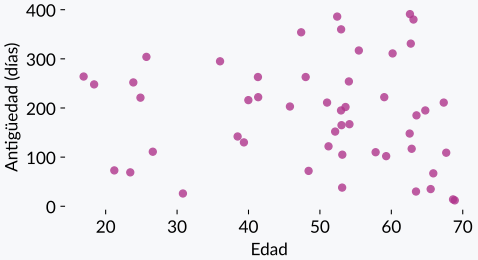
Diagrama de dispersión (*scatter*): cada punto es una observación, un eje por variable. La correlación de Pearson (Clase 2) la resume en un número; el gráfico te deja ver si esa relación es realmente lineal.

Recuerda la advertencia de la Clase 2: un valor de r cercano a 0 no significa “no hay relación”; puede haber una relación fuerte que simplemente no es una línea recta. El gráfico de dispersión es la forma de comprobarlo.

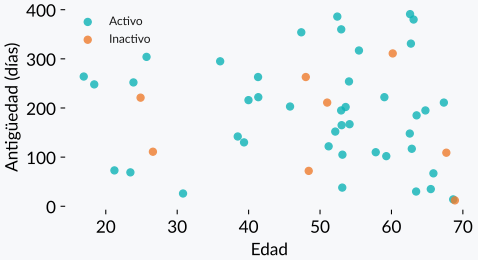
Relación: ejemplos con nuestros datos

Relación: cómo se mueven dos variables juntas

Dos variables numéricas:
edad vs. antigüedad (dispersión)



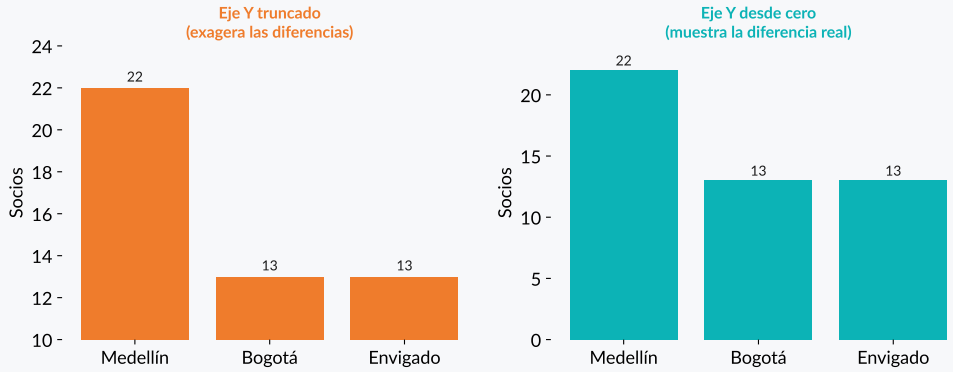
Una tercera variable con color:
edad vs. antigüedad, por estado



Escalas: el eje que decide lo que ves

El mismo dato, con un eje distinto, cuenta una historia distinta. Para gráficos de barras, el eje que mide la magnitud **debe empezar en cero**: el ojo compara el *tamaño* de las barras, y truncar el eje rompe esa comparación.

Mismos datos (socios por ciudad): dos ejes, dos impresiones distintas



¿Nunca se trunca un eje, entonces?

La regla “empieza en cero” es estricta para **barras** (donde el área y la altura son la comparación). Para **líneas** que muestran una tendencia en el tiempo, truncar el eje es aceptable y a veces necesario para ver el movimiento, siempre que:

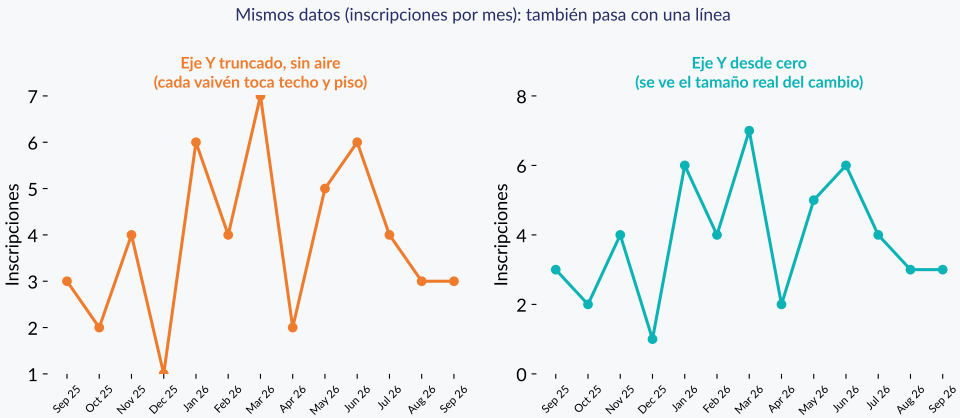
- lo digas explícitamente (una nota al pie, o el rango del eje visible),
- no sea tu única forma de “inventar” una tendencia que no existe.

Pregunta de control

Si alguien solo mira la forma del gráfico, sin leer los números de los ejes, ¿se llevaría una impresión correcta?

Una tendencia, truncada y sin truncar

Lo mismo pasa con una línea: quitarle el aire al eje hace que cualquier vaivén se vea como un cambio brusco. Son los mismos datos de inscripciones por mes que ya viste; aquí el único cambio es el rango del eje Y.



Etiquetas: lo mínimo para que se entienda solo

Un gráfico bueno se entiende sin que tú estés al lado explicándolo.

- **Título**: la conclusión, no la descripción. Mejor “Medellín concentra el 44 % de los socios” que “Socios por ciudad”.
- **Ejes**: nombre y unidad (`Socios`, no un número suelto).
- **Fuente y fecha**: de dónde salen los datos y de cuándo son.
- **Etiquetas directas sobre la barra o el punto**, en vez de una leyenda aparte, cuando hay pocas categorías: le ahorras a la audiencia ir y venir entre el gráfico y la leyenda.

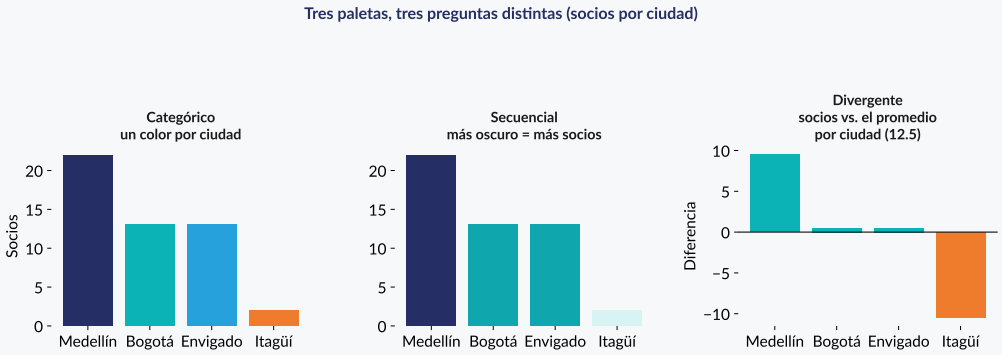
Color: con propósito, no por decoración

Categórico	Secuencial	Divergente
Colores distintos sin orden entre ellos. Ejemplo: ciudad, plan. Máximo 5 a 6 colores: más que eso, nadie los distingue.	Un solo color, de claro a oscuro. Para una variable que va de menos a más. Ejemplo: densidad, intensidad.	Dos colores que se alejan de un punto central. Para valores por encima o por debajo de un promedio, o positivos y negativos.

Usa el color para **resaltar lo que importa**: una sola categoría en color y el resto en gris comunica más que diez colores compitiendo por la atención. Y revisa que tu paleta se distinga también para quienes tienen daltonismo (evita depender solo de rojo y verde).

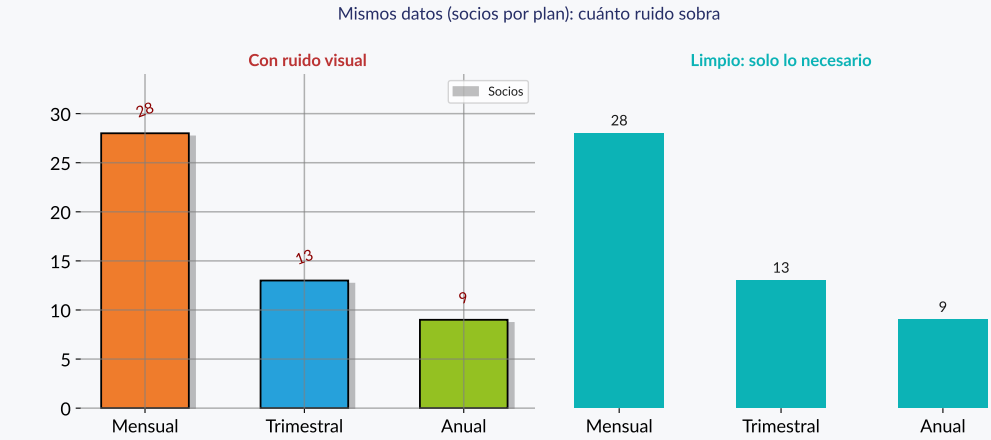
Las tres paletas, con un ejemplo real

Mismo dato (socios por ciudad), tres preguntas distintas según cómo uses el color: ¿qué ciudad es cada una, qué tanto tiene, o está por encima o por debajo del promedio?



Reducir el ruido visual

Edward Tufte lo resume con la idea de *data-ink ratio*: la proporción del gráfico dedicada a mostrar datos, frente a todo lo demás (rejillas pesadas, bordes, sombras, efectos 3D). Cada elemento que no ayuda a leer el dato **compite** por la atención con el dato mismo.



Checklist para quitar ruido

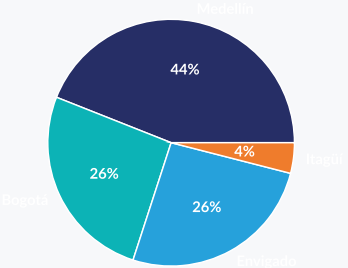
- ¿Necesito rejilla de fondo, o las etiquetas de valor ya bastan?
- ¿Necesito leyenda, o puedo poner la etiqueta directamente sobre la barra o la línea?
- ¿Los bordes y las sombras de las barras agregan información?
- ¿Estoy usando 3D en un gráfico que es, en realidad, de dos dimensiones? (El 3D distorsiona el tamaño relativo: nunca lo uses para comparar magnitudes.)
- ¿Cada color que usé significa algo, o solo está ahí porque la herramienta lo puso por defecto?

El pastel es el gráfico más mal usado

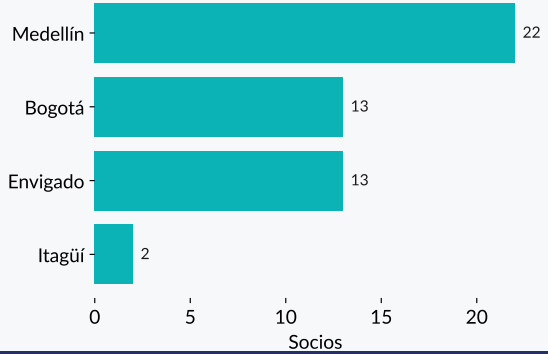
El ojo humano compara **largos** mucho mejor de lo que compara **ángulos** o **áreas**. Por eso un gráfico de pastel con rebanadas parecidas es casi imposible de leer con precisión, mientras que las mismas cifras en barras se comparan de un vistazo.

Misma composición (socios por ciudad), dos formas de mostrarla

Pastel: ¿cuál es más grande, Bogotá o Envigado?



Barras: la comparación es inmediata



Doble eje Y: dos escalas, una sola impresión

Un gráfico de doble eje Y pone dos variables distintas en el mismo gráfico, cada una con su propio eje vertical, compartiendo el eje X.

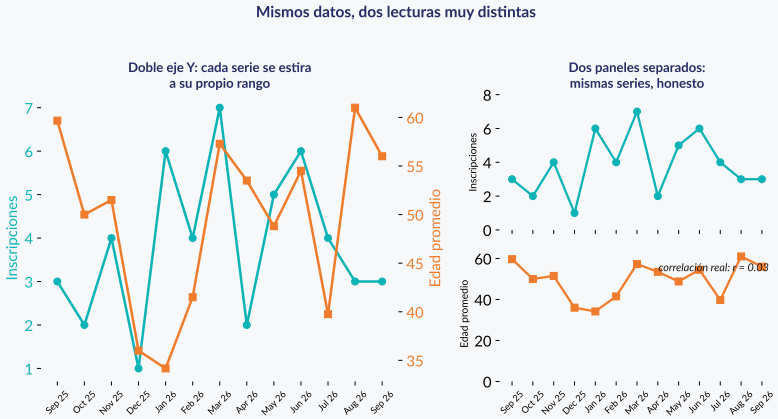
Por qué es tan fácil que engañe

Cada eje se ajusta, casi siempre en automático, al rango de **su propia** serie. El resultado es que las dos líneas terminan ocupando toda la altura del gráfico, sin importar si las variables tienen algo que ver entre sí. El ojo lee “suben y bajan juntas” aunque la relación real sea nula.

Regla práctica: si necesitas comparar dos variables en unidades distintas, casi siempre es más honesto mostrarlas en **paneles separados** (uno encima del otro, mismo eje X) que forzarlas en un solo gráfico con dos escalas libres.

Ejemplo: inscripciones y edad promedio, mes a mes

Dos series reales de nuestros datos, prácticamente sin relación entre sí (correlación real $r = 0{,}03$). A la izquierda, el mismo gráfico de doble eje que verías por defecto en casi cualquier herramienta; a la derecha, las mismas series en paneles separados.



Otros gráficos engañosos frecuentes

- **Orden arbitrario**: categorías en el orden en que llegaron en el archivo, en vez de ordenadas por valor. Oculta el patrón que el gráfico debería mostrar.
- **Comparar cosas no comparables**: ya lo viste en la Clase 8, al mezclar un precio mensual con uno anual sin llevarlos a la misma escala antes de graficar.
- **Promedios sin tamaño de muestra**: un promedio de 2 observaciones (Itagüí, Clase 9) graficado junto a uno de 22 sin ninguna indicación de que no son igual de confiables.

Otros gráficos que no vimos hoy

Barras, líneas, histograma, boxplot, dispersión y pastel cubren la mayoría de los casos, pero no todos.

Violín

Como el boxplot, pero muestra la forma completa de la distribución, no solo sus cuartiles.
seaborn.violinplot →

Barras con barras de error

Un promedio junto con su incertidumbre (desviación estándar o intervalo de confianza).
matplotlib.pyplot.errorbar →

Mapa de calor

Dos categorías cruzadas, con color en vez de barras; útil cuando una tabla cruzada tiene demasiadas filas.
seaborn.heatmap →

Otros gráficos que no vimos hoy

Área

Como una línea, pero con el espacio debajo relleno. Comunica bien una cantidad que se acumula en el tiempo.
matplotlib.pyplot.fill_between →

Burbujas

Un gráfico de dispersión con una tercera variable codificada en el tamaño del punto, además de las dos de los ejes.
matplotlib.pyplot.scatter →

Treemap

Composición con muchas categorías, donde el pastel ya no es legible: rectángulos de área proporcional.
plotly: Treemap charts →

Checklist final antes de publicar un gráfico

1. ¿Qué pregunta responde? ¿Se nota con solo mirarlo?
2. ¿Elegí el tipo de gráfico según esa pregunta (Hora 1), no por costumbre?
3. ¿El eje de magnitud empieza en cero, o expliqué por qué no?
4. ¿Tiene título, ejes con unidad, y fuente?
5. ¿Cada color significa algo?
6. ¿Quité todo lo que no ayuda a leer el dato?

Antes de compartirlo

Muéstraselo a alguien que no conozca los datos, durante 5 segundos. Si no puede decirte el mensaje principal, el gráfico todavía no está listo.

Actividad práctica

Taller de la sesión

En Google Colab vas a construir, paso a paso, los tipos de gráfico de esta clase con matplotlib y pandas sobre datos reales del curso. Al final del notebook hay un taller: rediseñar tres gráficos deficientes y justificar, con lo visto hoy, cada decisión de rediseño.

El notebook incluye enlaces a la documentación oficial (en español e inglés) de cada tipo de gráfico, para que los uses como referencia en tus propios proyectos.

Producto esperado

Entregable

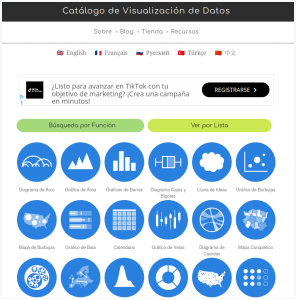
El notebook completo de la sesión: las celdas guiadas de cada tipo de gráfico, y el taller final con los tres gráficos rediseñados, cada uno con una justificación escrita de qué principio de esta clase aplicaste y por qué.

Cierre y próxima sesión

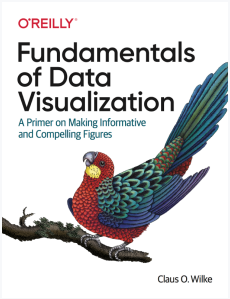
- Un gráfico efectivo responde una pregunta concreta, con el tipo de gráfico correcto para esa pregunta.
- Escalas honestas, etiquetas completas, color con propósito y sin ruido visual son lo que separa un gráfico que informa de uno que solo decora.
- Los gráficos engañosos casi nunca son mentiras explícitas: son decisiones de diseño (un eje, un orden, un tipo de gráfico) que cambian la impresión sin cambiar los datos.
- Próxima sesión, **Clase 12, MasterClass**: recapitulación presencial del Módulo 2 completo (Pandas, integración de fuentes y visualización) antes de entrar al Módulo 3 (Power BI).

Referencias para seguir explorando

Dos recursos gratuitos, en línea, para consultar tipos de gráfico y principios de visualización más allá de lo que vimos hoy.



Data Viz Catalogue (en español): catálogo visual de tipos de gráfico, con qué es, cuándo usarlo y qué variaciones existen.
datavizcatalogue.com/ES →



Fundamentals of Data Visualization, Claus Wilke: libro completo y gratuito sobre los principios de hoy (selección del gráfico, color, escalas). En inglés.
clauswilke.com/dataviz →

¡Gracias!