Esumer
Educación Superior

De la analítica descriptiva a la predictiva

Del qué pasó al qué va a pasar

Módulo: Módulo 4: Innovar (Analítica Predictiva y Storytelling)

Semana 10 · Clase 19 · Nov 10 al 15 · Virtual

Docente: Cristian A. Jimenez C., MSc — Nov 10 al 15

Agenda de hoy (3 horas)

Hora 1	Hora 2	Hora 3
De describir a predecir: variable objetivo, variables explicativas, correlación y causalidad.	Cómo aprende un modelo: tareas supervisadas, entrenamiento y prueba, y cómo elegir y crear sus características.	Gini, entropía y χ^2 con los datos del gimnasio; herramientas con sus pros y contras, y la actividad.

Hasta ahora contaste **qué pasó** y **por qué**: el 80 % de los socios del gimnasio sigue activo, y los que viven lejos se retiran más. Hoy damos el paso siguiente: usar esos datos para **anticipar qué va a pasar**. En la Clase 20 lo harás con Python.

Palabras nuevas de hoy

Variable objetivo	Lo que quieres predecir. También se llama *target* o *y*. Ejemplo: si el socio sigue activo.
Variables explicativas	Lo que usas para predecir. También se llaman *características*, *features* o *X*. Ejemplo: distancia a la sede, plan.
Modelo	Una regla aprendida de los datos que, con las variables explicativas, da una predicción.
Clasificación y regresión	Las dos tareas supervisadas: predecir una categoría (activo o no) o un número (cuántas visitas).
Entrenamiento y prueba	Los datos con que el modelo aprende, y los que se guardan aparte para comprobar si acierta con casos que no vio.
Sobreajuste	Cuando el modelo memoriza los casos de entrenamiento y falla con los nuevos.
Selección de características	Elegir qué columnas entran al modelo y cuáles no.
Extracción de características	Crear columnas nuevas, más útiles, a partir de las que tienes.
Fuga de información	Usar sin querer un dato que delata la respuesta y que no tendrías al momento de predecir (en inglés, *data leakage*).

Cuatro preguntas, cuatro tipos de analítica

Cada tipo responde una pregunta distinta sobre los mismos datos. Las dos primeras ya las hiciste en los Módulos 2 y 3.

Descriptiva
¿Qué pasó?

240 de 300 socios siguen activos (80,0 %).
Tarjetas, barras (Clase 14).

Diagnóstica
¿Por qué pasó?

A menos de 6 km sigue activo el 88,0 %; a 6 km o más, el 61,5 %.
Comparar grupos (Clase 14).

Predictiva
¿Qué va a pasar?

¿Qué socios nuevos tienen más riesgo de retirarse?
Hoy y Clase 20.

Prescriptiva
¿Qué debemos hacer?

¿A quién llamamos esta semana, y con qué oferta?
Fuera del alcance del curso.

más valor para decidir, y también más supuestos y más riesgo de equivocarse

Variable objetivo y variables explicativas

Un problema predictivo empieza por separar las columnas en dos grupos:

distancia	plan	edad	sexo	visitas	...	activo
2,1	Trimestral	28	F	69		No
0,2	Mensual	69	M	68		Sí
0,6	Anual	54	F	74		Sí

Variables explicativas (X): lo que sabes de cada socio

Objetivo (y)

- Cada **fila** es un caso: aquí, un socio. Siempre define qué es una fila antes de empezar.
- El objetivo debe estar **registrado en el pasado**: el modelo aprende de socios de los que ya sabemos si se quedaron.

Tres socios reales del archivo del gimnasio (`id_socio` 38, 12 y 46): distancia en km, edad al 30 de septiembre de 2026 y visitas registradas.

Cómo formular una pregunta predictiva

Una buena pregunta predictiva se puede escribir con esta plantilla:

Para decidir qué haremos | **quiero predecir** el objetivo | **de cada** unidad (la fila) | **usando** lo que sé en ese momento | **con anticipación** de cuánto tiempo

Ejemplo con el gimnasio

Para decidir a qué socios nuevos llamar en su primer mes, **quiero predecir** si seguirán activos **de cada** socio recién inscrito, **usando** su plan, su edad y la distancia de su casa a la sede, **con anticipación** de unos meses antes de que venza su plan.

La última parte es la que más se olvida: si predices el día en que el socio ya se fue, la predicción no sirve para nada.

Correlación no es causalidad

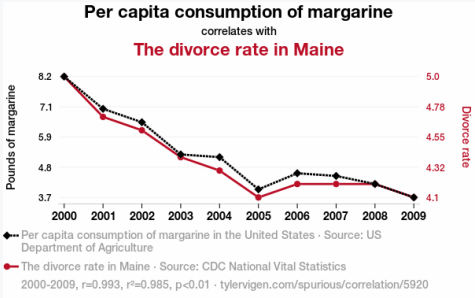
Que dos variables se muevan juntas no prueba que una cause la otra. Para **predecir**, la relación basta; para **decidir qué cambiar**, no.

Relación en los datos	¿Sirve para predecir?	¿Prueba una causa?
Plan Anual: 96,2 % activos. Plan Mensual: 77,9 %.	Sí, es una pista útil.	No: un plan anual casi no alcanza a vencer dentro de un año de datos (Clase 14).
A 6 km o más, 61,5 % activos. A menos de 6 km, 88,0 %.	Sí, y se conoce desde la inscripción.	Tampoco del todo: puede ser la distancia, o algo que va con ella, como el tráfico o el horario de trabajo.

Tres explicaciones antes de hablar de causa

Azar (pocos casos: el plan Semestral tiene solo 10 socios), **una tercera variable** que mueve a las dos, o **causa al revés**. Para probar una causa hace falta un experimento, por ejemplo una oferta a un grupo y no a otro.

Correlaciones absurdas, pero casi perfectas



Consumo de margarina en EE. UU. y tasa de divorcios en Maine, 2000 a 2009: $r = 0{,}993$.



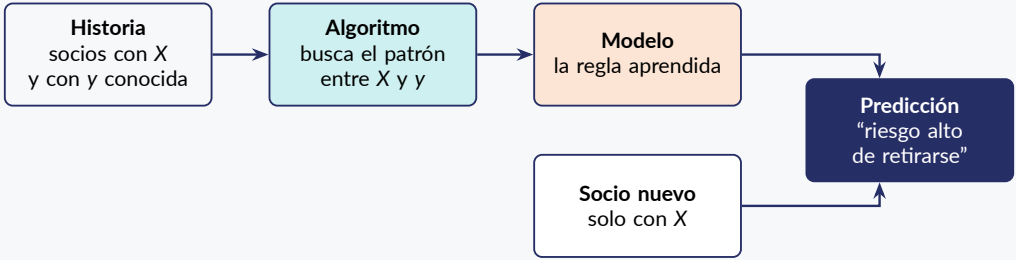
Consumo de yogur en EE. UU. y búsquedas en Google de “i cant even”, 2004 a 2021: $r = 0{,}939$.

¿Por qué salen tan altas? (1) Las dos series **cambian con el tiempo**: casi todo lo que sube o baja año tras año se “correlaciona”. **(2)** El autor cruzó **millones de pares** de variables y muestra las que coinciden por azar. **(3)** El **doble eje** (Clase 11) se ajusta para que las líneas se encimen. Un modelo que use la margarina para predecir divorcios acertaría en esos años y fallaría en los siguientes.

Gráficas sin modificar de Tyler Vigen, Spurious Correlations (correlaciones 5920 y 2203), licencia CC BY 4.0.

La idea del Machine Learning supervisado

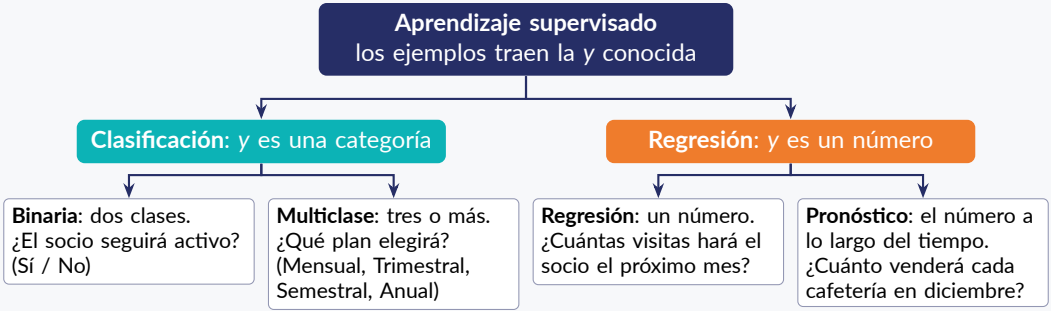
"Supervisado" significa que aprende de ejemplos **con la respuesta conocida**, como un estudiante que practica con ejercicios resueltos.



- El modelo no "sabe" por qué se retira la gente: encuentra patrones que se repitieron en el pasado.
- Si el futuro cambia (una sede nueva, una competencia), el patrón puede dejar de valer. Por eso se vuelve a revisar.

Las tareas supervisadas

La variable objetivo y decide la tarea: si es una categoría, clasificación; si es un número, regresión. Las dos predicen.

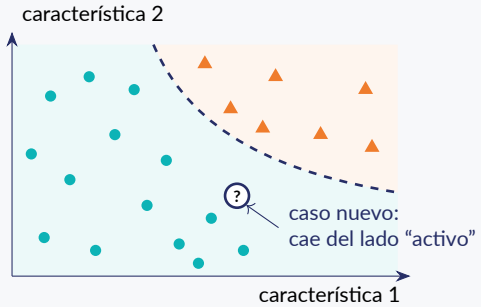


¿Y si no hay y?

Es aprendizaje **no supervisado**: por ejemplo, agrupar a los socios en segmentos parecidos sin decirle al modelo qué buscar. No hay respuesta correcta con qué comparar, y no es tema de este curso.

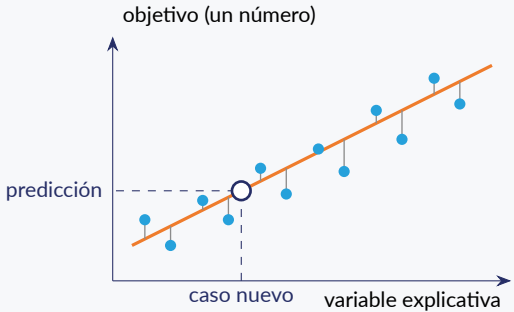
Las dos tareas, en un dibujo

Clasificación: ¿de qué lado cae?



● activos ▲ inactivos. El modelo aprende una **frontera** que separa las clases. A un caso nuevo le asigna la clase de la zona donde cae.

Regresión: ¿qué valor tendrá?



El modelo aprende una **línea** (o curva) que sigue la tendencia de los puntos. Para un caso nuevo, la predicción es la altura de la línea. Las rayas grises son los **errores**: lo que tendrás que medir en la Clase 20.

Esquemas: los puntos no son datos reales; solo muestran la idea de cada tarea.

Clasificación y regresión: sus diferencias

	Clasificación	Regresión
Pregunta típica	¿Cuál? ¿Sí o no?	¿Cuánto? ¿Cuántos?
Qué responde el modelo	Una clase, o la probabilidad de cada una: “82 % de seguir activo”.	Un número: “9 visitas el próximo mes”.
Cómo se mide si acierta	Porcentaje de aciertos, y a cuántos de cada clase encuentra.	Cuánto se equivoca, en las unidades del objetivo, y el R^2 (Clase 20).
Línea base	Decir siempre la clase más frecuente: 80 % de aciertos en el gimnasio.	Decir siempre el promedio.
Criterios para elegir columnas	Gini, entropía, χ^2, ANOVA.	Correlación.
Modelos típicos	Regresión logística, árbol de decisión, *k* vecinos más cercanos.	Regresión lineal (Clase 20), árbol de regresión.

Cuidado con el nombre. La **regresión logística** es de **clasificación**: calcula la probabilidad de una clase, aunque se llame regresión.

El pronóstico es especial. El orden del tiempo importa: se entrena con los meses pasados y se prueba con los siguientes, no con un reparto al azar.

Entrenamiento y prueba

El examen que el modelo no ha visto. Si evalúas al modelo con los mismos casos con que aprendió, es como calificar un examen con las preguntas que el estudiante ya memorizó.



300 socios del gimnasio, repartidos al azar

1. El modelo aprende **solo** con el grupo de entrenamiento.
2. Predice el grupo de prueba como si fueran socios nuevos.
3. Comparas sus predicciones con lo que de verdad pasó.

En Python (Clase 20), una sola función hace el reparto:

```
from sklearn.model_selection import
  train_test_split

X = socios[["distancia_sede_km", "edad"]]
y = socios["activo"]

X_train, X_test, y_train, y_test =
  train_test_split(X, y,
    test_size=0.2, random_state=42)
```

`test_size=0.2` deja el 20 % para la prueba; `random_state` hace que el reparto sea el mismo cada vez que lo ejecutas.

Memorizar no es aprender

Un modelo que acierta todo en entrenamiento y falla en prueba está **sobreajustado**: se aprendió los casos, no el patrón.

Antes de celebrar: la línea base

Compara siempre con no hacer nada. Si el modelo dice “activo” para todos los socios, sin mirar ningún dato, ya acierta **240 de 300: el 80 %**. Esa es la **línea base**.



Qué significa

Un modelo que acierta el 82 % apenas mejora a no hacer nada. Pregunta siempre: ¿cuánto mejor que la línea base?

Y además

Ese 80 % nunca encuentra a un solo socio que se va a retirar, que es justo a quien quieres llamar. Hay que mirar también a quién acierta, no solo cuántos.

Características: elegir y crear

El modelo solo ve las columnas que le das. Hay dos tareas, y ninguna es automática: las dos piden conocer el negocio.

Selección: quedarse con las útiles



De 6 columnas quedan 2. Las demás no se transforman: se dejan por fuera.

Extracción: crear columnas nuevas



De fecha de nacimiento y fecha de corte sale la edad; de las coordenadas, la distancia.

Por qué seleccionar

Menos columnas: un modelo más fácil de explicar, que se equivoca menos con casos nuevos y que necesita menos datos.

Por qué extraer

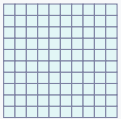
El dato crudo casi nunca es la mejor pista: una fecha sola dice poco; la antigüedad que sale de ella dice mucho.

La maldición de la dimensionalidad

¿Por qué no usar todas las columnas? Porque cada columna nueva **multiplica** el espacio que los datos deben llenar.



1 columna, 10 tramos
10 casillas
30 socios por casilla



2 columnas
100 casillas
3 socios por casilla



3 columnas
1.000 casillas
0,3 socios por casilla

Con **300 socios** y 10 tramos por columna, con 3 columnas ya hay más casillas que socios: casi todas quedan **vacías**. El modelo adivina donde nunca vio a nadie y **memoriza** los pocos casos que vio (sobreajuste).

Qué hacer

Seleccionar y extraer: pocas columnas buenas. Regla práctica: unos 10 casos de la clase menos frecuente por columna. Con 60 inactivos, unas 6 columnas.

Extracción: ya lo has hecho en el curso

Cada columna nueva que creaste es una característica extraída:

Dato crudo	Característica	Cómo	Dónde
`fecha_nacimiento`	edad	diferencia con la fecha de corte	Clases 8 y 13
`fecha_inscripcion`	días como socio	`DATEDIFF` o resta de fechas	Clase 14
latitud y longitud	distancia a la sede, en km	fórmula de distancia entre dos puntos (venía calculada)	Clases 13 y 14
`hora_entrada`	hora del día, franja	`HOUR`, `pd.cut`	Clases 8 y 14
tabla de asistencias	visitas por socio	agrupar y contar (`groupby`)	Clase 9

Una técnica más: combinar muchas columnas en pocas

Cuando hay decenas de columnas numéricas parecidas, el **análisis de componentes principales** (PCA) las resume en unas pocas columnas nuevas que conservan casi toda la información. El costo: esas columnas nuevas ya no tienen un significado de negocio fácil de explicar.

Selección: cinco preguntas para cada columna

1. **¿La tendré al momento de predecir?** Si no, es fuga de información.
2. **¿Se relaciona con el objetivo?** Compara activos e inactivos, o calcula la correlación.
3. **¿Repite lo que dice otra?** Visitas totales y días como socio tienen correlación de 0,62: dicen parte de lo mismo.
4. **¿Es confiable?** Muchos vacíos o errores la debilitan.
5. **¿Es justo y legal usarla?** Sexo, edad u origen pueden discriminar, aunque predigan.

Fuera desde el inicio

Los **identificadores**: `id_socio`, nombre, correo, teléfono. Son únicos por persona: el modelo los memoriza y no aprende nada que sirva para un socio nuevo. Además, son datos personales (Clase 1).

Los métodos automáticos

Existen métodos que ordenan o prueban combinaciones de columnas: por **filtro** (una medida, como la correlación), por **envoltura** (probar el modelo con distintos grupos) e **integrados** al modelo. Ayudan con la pregunta 2, pero ninguno responde la 1 ni la 5.

Selección con los datos del gimnasio

Promedios de los 240 activos y los 60 inactivos, al 30 de septiembre de 2026:

Columna candidata	Activos	Inactivos	Decisión
distancia a la sede (km)	4,3	7,4	**Entra.** Hay diferencia y se conoce desde la inscripción.
plan	Anual 96,2 %; Mensual 77,9 %		**Entra**, con la advertencia de la diapositiva de causalidad.
edad (años)	37,4	37,5	**Probablemente no aporta.** Casi no hay diferencia.
sexo	F 79,3 %; M 79,5 %		**Fuera.** No hay diferencia, y es un dato sensible.
visitas totales	62,4	35,0	**Cuidado.** Los activos llevan más tiempo yendo: es en parte consecuencia de seguir activo.
días sin venir	3,3	68,0	**Fuera: es fuga.** Ver la siguiente diapositiva.

Plan y sexo son categorías: se muestra el porcentaje de activos de cada grupo. Hay 9 socios sin sexo registrado.

La trampa: una columna que delata la respuesta

Días desde la última visita, en mediana:

Activos: **1 día**

Inactivos: **37 días**

Una regla tan simple como “si lleva más de 30 días sin venir, se retiró” acierta con el **91 %** de los socios. Supera la línea base del 80 %. Parece un gran modelo.

Pero no sirve

Un socio deja de venir **porque ya se retiró**. Esa columna describe la respuesta, no la anticipa. Cuando la tienes, ya es tarde para llamarlo.

La prueba de la fuga

Para cada columna pregunta: **¿la conocería el día en que tengo que decidir?** Si la decisión es en el primer mes del socio, solo vale lo que se sabe en ese primer mes.

Un resultado demasiado bueno para ser verdad casi siempre es una fuga de información.

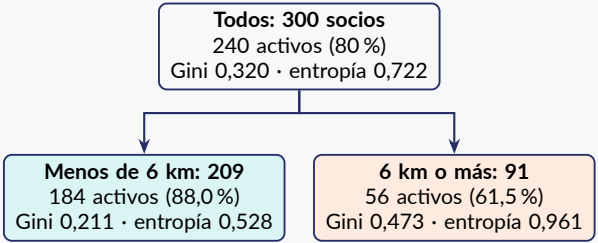
Criterios para medir cuánto aporta una columna

Los métodos por filtro le ponen un número a cada columna para ordenarlas. El criterio depende del tipo de columna y de objetivo:

Criterio	Qué mide	Cuándo se usa
Correlación	Si dos números suben o bajan juntos, en línea recta.	Columna numérica y objetivo numérico (Clase 20).
Índice de Gini	Qué tan **mezclado** queda cada grupo: 0 si todos son iguales.	Objetivo categórico. Es el criterio de los árboles de decisión.
Entropía y ganancia de información	También la mezcla, medida en bits. La ganancia es cuánto baja la entropía al separar por la columna.	Objetivo categórico. En scikit-learn se llama *información mutua*.
Chi cuadrado (χ^2)	Si la tabla cruzada se aleja de lo que se esperaría si no hubiera relación. Da un **valor p**.	Columna categórica y objetivo categórico.
ANOVA (prueba F)	Si los promedios de un número cambian entre los grupos del objetivo.	Columna numérica y objetivo categórico.

En Orange, widget **Rank**. En scikit-learn, `chi2`, `mutual_info_classif` y `f_classif`.

Gini y entropía: ¿se ordena el grupo?



Al separar por distancia, el grupo cercano quedó **más puro** (casi todos activos); el lejano, más mezclado. Promediando según el tamaño de cada grupo, el Gini baja de 0,320 a 0,290: una **disminución de 0,030**. La entropía baja de 0,722 a 0,660: una **ganancia de información de 0,062**.

Las fórmulas

p es la proporción de cada clase en el grupo.

Gini $= 1 - \sum p^2$

Entropía $= -\sum p \log_2 p$

Para todos los socios:

$1 - (0{,}8^2 + 0{,}2^2) = 0{,}32$

Cómo se leen

0 es un grupo puro. El máximo (Gini 0,5; entropía 1, con dos clases) es mitad y mitad. Una buena columna separa en grupos más puros que el original.

Los tres criterios con los datos del gimnasio

Objetivo: `activo`. Edad en tres grupos (menos de 30, 30 a 44, 45 o más); sexo, sin los 9 socios que no lo tienen.

Columna	Disminución de Gini	Ganancia de información	χ^2 (valor p)	Lectura
distancia (6 km)	0,030	0,062	27,8 (menos de 0,001)	La que más separa.
plan	0,013	0,036	12,2 (0,007)	Separa, con menos fuerza.
edad (3 grupos)	0,003	0,008	3,1 (0,21)	Sin evidencia de relación.
sexo	0,000	0,000	0,0 (0,98)	Ninguna relación.

Qué dicen juntos

Los tres criterios dan el **mismo orden**. El valor p de χ^2 dice si la relación podría ser azar: por debajo de 0,05, es poco probable que lo sea.

Lo que no dicen

"Días sin venir" (más de 30 o no) quedaría **primera** en los tres: Gini baja 0,157 y χ^2 da 146,8. Ningún criterio detecta la fuga de información: eso lo decides tú.

Herramientas: de arrastrar cajas a escribir código

Lo que acabas de calcular, y todo lo de la Hora 2, estas herramientas lo hacen por ti. Cambia **cómo** se lo pides.

Orange | **Weka** | **KNIME** | **RapidMiner AI Studio** | **Python**

Visual: arrastras bloques y los conectas. Sin programar.

Código: escribes cada paso. Control total.

- En las herramientas visuales, cada caja es un paso (leer el archivo, filtrar columnas, entrenar) y las flechas llevan los datos de un paso al siguiente. El flujo queda guardado, como los pasos aplicados de Power Query.
- Ninguna te salva de las preguntas de la Hora 2: todas pueden entrenar un modelo con fuga de información si no la detectas tú.

Orange Data Mining

Qué es

Herramienta visual del Laboratorio de Bioinformática de la Universidad de Liubliana (Eslovenia). Cada paso es un **widget** que se conecta con otros.

Licencia: gratuita y de código abierto (GPL).
Equipos: Windows, macOS y Linux.

Para características: los widgets **Rank** (ordena las columnas según cuánto se relacionan con el objetivo), **Select Columns** y **PCA**.

Sitio oficial: orangedatamining.com.

- \+ La más fácil para empezar: en minutos tienes un flujo funcionando.
- \+ Gráficos interactivos en cada paso: seleccionas puntos en un gráfico y pasan al siguiente widget.
- \+ Muy usada en la enseñanza, con tutoriales en video.
- \+ Complementos para texto, imágenes y otras tareas.
- – Pensada para explorar y aprender, no para procesos de la empresa que corren solos todos los días.
- – Con tablas muy grandes se vuelve lenta.
- – Pocos conectores a bases de datos y sistemas empresariales.

KNIME Analytics Platform

Qué es

Plataforma visual de flujos de trabajo, creada en la Universidad de Constanza (Alemania). Cada paso es un **nodo**.

Licencia: la plataforma de escritorio es gratuita y de código abierto (GPLv3). Compartir y automatizar flujos en servidor (KNIME Business Hub) es de pago.
Equipos: Windows, macOS y Linux.

- \+ Muy completa: preparar datos, unir fuentes, modelar y reportar en un mismo flujo, como un Power Query con modelos.
- \+ Miles de nodos y conectores (Excel, bases de datos, la web).
- \+ Puede ejecutar código de Python o R dentro del flujo.
- \+ Comunidad grande y flujos de ejemplo en KNIME Hub.
- – La curva de aprendizaje es mayor que la de Orange: hay tantos nodos que cuesta encontrar el correcto.
- – Consume bastante memoria del computador.
- – Sus gráficos son menos atractivos que los de Orange o Power BI.

Para características: los nodos **Linear Correlation** y **Correlation Filter** (quitar columnas redundantes), **Feature Selection Loop** y **PCA**.

Sitio oficial: knime.com/downloads.

RapidMiner AI Studio

Qué es

Herramienta visual de “arrastrar y soltar” con **operadores**. Nació como RapidMiner; pasó a Altair, que la llamó Altair AI Studio, y hoy aparece en el sitio de Siemens.

Licencia: comercial. Ha tenido ediciones gratuitas y para estudiantes, con condiciones que han cambiado: verifícalas antes de adoptarla.

- \+ Interfaz guiada, pensada para analistas de negocio.
- \+ Funciones de **AutoML**: prueba varios modelos por ti y los compara.
- \+ Integra cuadernos de Python y R con el flujo visual.
- \+ Muy usada en la industria y en cursos de minería de datos.
- – No es software libre: el uso en una empresa requiere licencia.
- – Los cambios de dueño y de nombre hacen confusa la documentación y las versiones.
- – El AutoML tienta a no entender lo que hace el modelo.

Para características: los operadores **Weight by Correlation**, **Optimize Selection** (prueba combinaciones de columnas) y **Principal Component Analysis**.

Sitio oficial: siemens.com/en-us/products/rapidminer/ai-studio.

Weka

Qué es

Colección clásica de algoritmos de aprendizaje automático de la Universidad de Waikato (Nueva Zelanda). Su ventana principal, **Explorer**, organiza el trabajo en pestañas.

Licencia: gratuita y de código abierto (GPL).
Equipos: Windows, macOS y Linux (funciona con Java).

Sitio oficial: waikato.github.io/weka-wiki.

- \+ Muchísimos algoritmos, con un libro y cursos en línea gratuitos de sus autores.
- \+ Una pestaña completa, **Select attributes**, solo para la selección de características.
- \+ Ligera: funciona bien en computadores modestos.
- – Interfaz antigua y poco intuitiva.
- – Preparar y limpiar datos es incómodo: conviene llegar con la tabla ya limpia (por ejemplo, desde pandas).
- – Su versión estable recibe pocas novedades; hoy se usa más en la enseñanza y la investigación que en las empresas.

Para características: en **Select attributes** eliges cómo evaluar cada columna (correlación, ganancia de información) y cómo buscar la mejor combinación.

Python: pandas y scikit-learn

Qué es

El lenguaje que usaste en los Módulos 1 y 2. **scikit-learn** es su librería de aprendizaje automático. Lo usas en Google Colab, sin instalar nada.

Licencia: gratuito y de código abierto.

Para características:

```
socios[columnas].corrwith(y)
SelectKBest(k=3)
PCA(n_components=2)
```

La primera línea calcula la correlación de cada columna con el objetivo `y` (en 0 y 1). Las otras dos vienen de scikit-learn: elegir las 3 mejores columnas y resumir en 2.

Sitio oficial: scikit-learn.org (selección de características).

- \+ Ya lo conoces: pandas para preparar, scikit-learn para modelar.
- \+ Control total y la mayor flexibilidad: si existe una técnica, hay una librería de Python que la tiene.
- \+ Es el estándar del mercado laboral en ciencia de datos.
- \+ El notebook documenta cada paso y se puede repetir.
- – Hay que programar: un error de sintaxis detiene todo.
- – Nadie te impide un error de método: dividir mal los datos o meter una fuga no da ningún mensaje de error.
- – Para alguien que no programa, el resultado es menos fácil de revisar que un flujo visual.

Comparación rápida

Herramienta	Forma de trabajo	Licencia	Aprenderla	Mejor para
Orange	Visual (widgets)	Gratis, abierta	Muy fácil	Explorar y aprender los conceptos de hoy, sin código.
Weka	Visual (pestañas)	Gratis, abierta	Media	Probar muchos algoritmos sobre una tabla ya limpia.
KNIME	Visual (nodos)	Gratis el escritorio	Media a alta	Flujos completos, de varias fuentes al modelo, repetibles.
RapidMiner AI Studio	Visual (operadores)	Comercial	Media	Empresas que ya la tienen y quieren AutoML guiado.
Python	Código	Gratis, abierta	Alta	Control total y lo que pide el mercado laboral.

Nuestra recomendación para el curso

En la Clase 20 usarás **Python** (Colab), porque ya lo conoces. Para ver los mismos conceptos sin código, prueba **Orange** con el archivo del gimnasio y el widget Rank.

Actividad: tu pregunta predictiva

Con los datos de tu proyecto:

1. Escribe una pregunta predictiva con la plantilla: para decidir …, quiero predecir … de cada …, usando …, con anticipación de …
2. Di si es de **clasificación** o de **regresión**.
3. Define qué es una **fila** y cuál es la **variable objetivo**. ¿Existe en tus datos, o hay que construirla?
4. Lista de 5 a 8 columnas candidatas y pasa cada una por las cinco preguntas de la selección.
5. Propón al menos una **característica extraída**: una columna nueva que crearías a partir de las que tienes.

Plantilla de la tabla de candidatas

Columna	¿La tendré?	¿Aporta?	¿Sensible?	Decisión
distancia	*Sí*	*Sí*	*No*	*Entra*
días sin venir	*No*	*Sí*	*No*	*Fuera: fuga*

Si tu proyecto no tiene un objetivo que predecir, usa los datos del gimnasio o los de Cafés Altavista (Clase 16).

Producto esperado

Un documento corto (una página) con:

1. La **pregunta predictiva**, escrita con la plantilla, y la decisión que apoya.
2. El tipo de problema (clasificación o regresión), qué es una fila y cuál es la variable objetivo.
3. La **tabla de columnas candidatas**, con la decisión y una frase de por qué para cada una.
4. Al menos una característica extraída y cómo la calcularías.
5. Un riesgo: una posible fuga de información, un dato sensible o una relación que podría no ser causal.

Para qué sirve

Es el insumo de la Clase 20: si tu objetivo es un número, con estas columnas entrenarás tu primera regresión lineal.

Cierre y próxima sesión

- Describir dice qué pasó; predecir anticipa qué va a pasar, a partir de patrones del pasado.
- Un problema predictivo se define con una **variable objetivo**, unas **variables explicativas** y la decisión que apoya. Si el objetivo es una categoría, es **clasificación**; si es un número, **regresión**.
- Se entrena con unos datos y se **prueba con otros**, y el resultado se compara con la **línea base**.
- Pocas columnas buenas valen más que muchas: cada columna de más multiplica el espacio que los datos deben llenar. Gini, entropía y χ^2 ayudan a ordenarlas, pero la pregunta más importante la respondes tú: **¿tendré este dato cuando tenga que decidir?**
- La herramienta importa menos que el método: Orange, KNIME, RapidMiner, Weka y Python cometen los mismos errores si tú no los detectas.

Próxima sesión: Clase 20

Regresión lineal con Python: ajustar un modelo, predecir, medir el error e interpretar los coeficientes en lenguaje de negocio.

Para seguir aprendiendo

Descargas

- Orange Data Mining
- KNIME Analytics Platform
- RapidMiner AI Studio
- Weka
- Google Colab (Python, sin instalar nada)

Documentación sobre características

- Orange: widget Rank
- KNIME: nodo Correlation Filter
- RapidMiner: Weight by Correlation
- scikit-learn: selección de características
- scikit-learn: PCA y descomposición
- scikit-learn: `train_test_split`
- Spurious Correlations (Tyler Vigen)

Los datos del Gimnasio Vitalis son ficticios, creados para el curso. Las cifras de esta presentación se calcularon con los 300 socios sin duplicados, con fecha de corte 30 de septiembre de 2026.

¡Gracias!