Esumer
Educación Superior

Regresión lineal con Python

Predecir un número y saber cuánto confiar en él

Módulo: Módulo 4: Innovar (Analítica Predictiva y Storytelling)

Semana 10 · Clase 20 · Nov 10 al 15 · Virtual

Docente: Cristian A. Jimenez C., MSc — Nov 10 al 15

Agenda de hoy (3 horas)

Hora 1	Hora 2	Hora 3
La idea: una recta que sigue a los datos, cómo se ajusta, cómo se leen sus coeficientes y cómo predice.	¿Qué tan bien predice?: residuos, MAE, RMSE y R^2. Regresión múltiple y “con lo demás igual”.	Los límites del modelo y los riesgos de extrapolar. La práctica, en Python o en Orange.

En la Clase 19 viste el mapa: si el objetivo es un número, la tarea es **regresión**; se entrena con unos datos, se prueba con otros y se compara con la **línea base**. Hoy construyes el modelo de regresión más sencillo y más usado, y aprendes a explicarlo en lenguaje de negocio.

Palabras nuevas de hoy

Regresión lineal	Modelo que predice un número con una recta (o, con varias variables, un plano).
Intercepto y pendiente	Los dos números que definen la recta: dónde corta el eje y cuánto sube por cada unidad de la variable.
Coeficiente	El número que multiplica a cada variable explicativa. La pendiente es un coeficiente.
Residuo	Lo real menos lo predicho, en cada caso. Es el error del modelo en ese caso.
Mínimos cuadrados	La regla para elegir la recta: la que hace más pequeña la suma de los residuos al cuadrado.
MAE, RMSE, R^2	Tres formas de medir qué tan bien predice el modelo.
Extrapolar	Predecir fuera del rango de los datos con que aprendió el modelo.

El caso de hoy: ¿cuántas bicicletas preparar?

Capital Bikeshare alquila bicicletas en Washington D. C. Cada noche decide cuántas bicicletas y cuánto personal tener listos para el día siguiente.

Tenemos **731 días reales** (2011 y 2012): cuántas bicicletas se alquilaron y el clima de cada día.

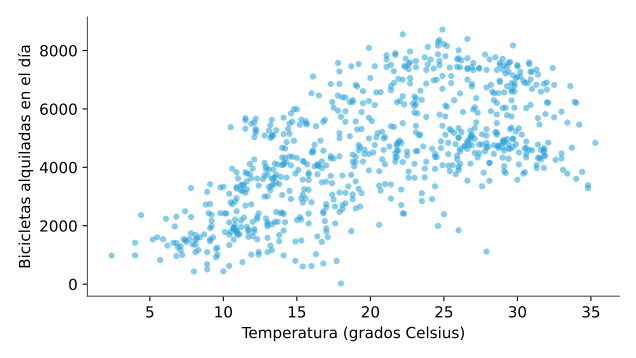
La pregunta predictiva (Clase 19)

Para decidir cuántas bicicletas y personas preparar, **quiero predecir** los alquileres **de cada** día, **usando** el pronóstico del clima y el calendario, **con anticipación** de un día.

Columna	Rol
`alquileres`	Objetivo y (un número)
`temperatura_c`	Explicativa
`humedad`, `viento`	Explicativas
`lluvia` (0 o 1)	Explicativa
`es_2012` (0 o 1)	Explicativa
`dia_laboral` (0 o 1)	Explicativa
Reparto	80 % entrenamiento (584 días) y 20 % prueba (147)

Datos: Bike Sharing Dataset (Capital Bikeshare, Washington D. C.), UCI Machine Learning Repository, CC BY 4.0. Fanaee-T y Gama (2013).

Antes de modelar, mirar



Cada punto es un día. Con más temperatura hay más alquileres: la correlación es **0,627**, positiva y moderada (Clase 11).

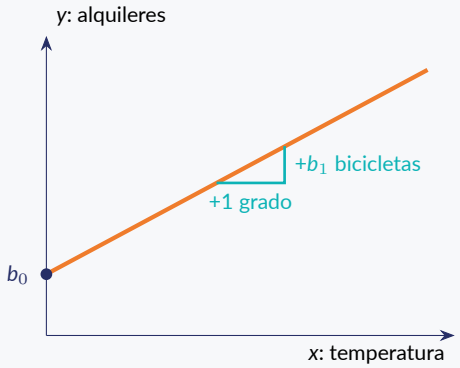
La regresión lineal supone que la relación es, más o menos, una **recta**. Mira con cuidado la derecha: en los días más calurosos la nube deja de subir. Volveremos a eso.

Regla

Nunca ajustes un modelo sin haber mirado antes el gráfico de dispersión.

Datos: Bike Sharing Dataset (Capital Bikeshare, Washington D. C.), UCI Machine Learning Repository, CC BY 4.0. Fanaee-T y Gama (2013).

La idea: una recta



$$\hat{y} = b_0 + b_1 \cdot x$$

- $\hat{y}$ ("y gorro"): la **predicción**.
- b_0, el **intercepto**: el valor de la recta cuando x es 0.
- b_1, la **pendiente**: cuánto cambia $\hat{y}$ cuando x sube en 1.

Ajustar el modelo es **encontrar** b_0 **y** b_1 a partir de los datos de entrenamiento. Todo lo demás (predecir, medir, explicar) sale de esos dos números.

¿Cuál recta? Mínimos cuadrados



Esquema; los puntos no son datos reales.

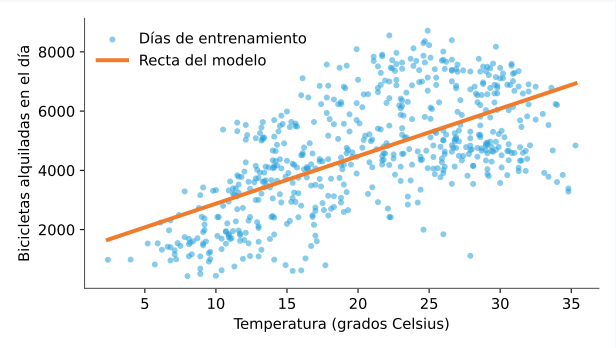
Hay infinitas rectas posibles. Cada una deja una distancia vertical entre cada punto y la recta: el **residuo**.

La regresión lineal elige la recta que hace más pequeña la **suma de los residuos al cuadrado**. Por eso se llama de **mínimos cuadrados**.

¿Por qué al cuadrado?

Para que los residuos positivos y negativos no se cancelen, y para castigar más los errores grandes. No lo calculas tú: lo hace `LinearRegression()` en Python o el widget **Linear Regression** en Orange.

La recta de nuestros datos



Con los 584 días de entrenamiento:

$$\hat{y} = 1272{,}76 + 160{,}35 \cdot \text{temperatura}$$

En Python:

```
modelo = LinearRegression()
modelo.fit(X_train, y_train)
modelo.intercept_   # 1272.76
modelo.coef_        # [160.35]
```

En Orange: widget **Linear Regression**, salida **Coefficients**.

Datos: Bike Sharing Dataset (Capital Bikeshare, Washington D. C.), UCI Machine Learning Repository, CC BY 4.0. Fanaee-T y Gama (2013).

Leer los coeficientes en lenguaje de negocio

Un coeficiente no se entrega como un número suelto: se traduce a la decisión.

	Así no	Así sí
Pendiente 160,35	"El coeficiente de temperatura es 160,35."	"Por cada grado más de temperatura, se alquilan en promedio unas **160 bicicletas más** al día."
Intercepto 1272,76	"A 0 grados se alquilan 1273 bicicletas."	No se lee como predicción: ningún día de los datos llegó a 0 grados (el más frío tuvo 2,4). Solo fija la altura de la recta.

Las unidades importan

La pendiente está en **bicicletas por grado**. Si la temperatura estuviera en grados Fahrenheit, el número cambiaría, aunque la relación sea la misma.

Promedio, no certeza

"En promedio" es parte de la frase: un día concreto puede quedar muy lejos de la recta.

Predecir con la recta

Para un día de 25 grados, se reemplaza en la ecuación:

$$\hat{y} = 1272{,}76 + 160{,}35 \times 25 = 5281 \text{ bicicletas}$$

En Python

```
dia = pd.DataFrame({"temperatura_c": [25]})
modelo.predict(dia)   # array([5281.4])
```

En Orange

Widget **Create Instance** con `temperatura_c` = 25, conectado con **Predictions** junto al modelo.

¿5281 es lo que va a pasar?

Es lo que la recta dice para un día *típico* de 25 grados. Para saber cuánto confiar en esa cifra hay que medir cuánto se equivoca el modelo: es la Hora 2.

Los residuos, día por día

Tres días reales de entrenamiento, con el modelo de la temperatura:

Día	Temperatura	Real	Predicho	Residuo
miércoles 5 ene. 2011	9,3	1600	2764	-1164
lunes 25 jul. 2011	30,5	3840	6163	-2323
sábado 22 sep. 2012	26,6	8395	5538	$+2857$

Cómo se leen

Residuo negativo: el modelo predijo **de más**. Positivo: **de menos**. El 22 de septiembre de 2012 se alquilaron casi 2900 bicicletas más de lo previsto.

Para qué sirven

Los residuos son la parte que el modelo **no explica**. De ellos salen las medidas de error y, mirados en un gráfico, sus límites.

Tres medidas del error

	Qué es	Cómo se lee
MAE	Promedio de los residuos en valor absoluto.	"En promedio, el modelo se equivoca en tantas bicicletas." La más fácil de explicar.
RMSE	Raíz del promedio de los residuos al cuadrado.	También en bicicletas, pero castiga más los errores grandes. Siempre es mayor o igual que el MAE.
R^2	$1 - \frac{\text{suma de residuos}^2}{\text{suma de distancias al promedio}^2}$	Qué parte de la variación explica el modelo. 1 es perfecto; 0 es lo mismo que predecir el promedio.

Con los 147 días de prueba, que el modelo no vio:

Modelo	MAE	RMSE	R^2
Línea base (siempre el promedio)	1712,0	2022,2	$-0{,}020$
Simple (temperatura)	1291,7	1545,9	0,404

El R^2 es orientativo

Nuestro modelo simple tiene R^2 de **0,388** con los días de entrenamiento y de **0,404** con los de prueba.

Son parecidos: buena señal de que el modelo no memorizó (Clase 19). Si el de prueba fuera mucho más bajo, habría sobreajuste. El que se reporta es el de **prueba**.

¿Es bueno un R^2 de 0,40?

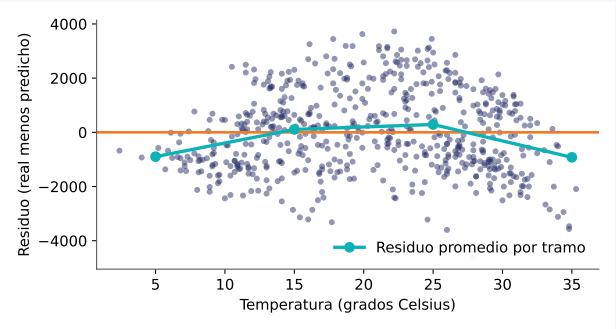
Depende de la decisión. Para planear bicicletas, mejora a la línea base en unas 420 bicicletas diarias de error, pero deja cerca del 60 % de la variación sin explicar.

Tres errores comunes

- Creer que hay un R^2 “mínimo aceptable” para todo.
- Creer que un R^2 alto prueba una causa (Clase 19).
- Mirar solo el R^2: un modelo puede tener R^2 aceptable y fallar siempre en el mismo tipo de días. Para eso están los residuos.

Por eso se reporta siempre junto al **MAE**, que dice el error en las unidades del negocio.

Los residuos tienen forma: la relación no es recta



Si el modelo fuera adecuado, los residuos quedarían al azar alrededor de cero. Aquí forman un **arco**:

Temperatura	Residuo prom.
0 a 10	-897
10 a 20	107
20 a 30	290
30 a 40	-923

Con frío y con calor fuerte, predice de más. Una recta no puede doblarse: es un **límite del modelo**, no un error tuyo.

Datos: Bike Sharing Dataset (Capital Bikeshare, Washington D. C.), UCI Machine Learning Repository, CC BY 4.0. Fanaee-T y Gama (2013).

Regresión lineal múltiple

Con varias variables explicativas, la idea es la misma: un coeficiente por variable.

$$\hat{y} = b_0 + b_1 \cdot \text{temperatura} + b_2 \cdot \text{humedad} + \cdots + b_6 \cdot \text{lluvia}$$

"Con lo demás igual"

Cada coeficiente es el cambio en la predicción cuando esa variable sube en 1 y **las demás se mantienen fijas**. Es lo que hace útil a la regresión múltiple: separa el efecto de cada variable.

Variables de 0 y 1

En `lluvia`, pasar de 0 a 1 es pasar de un día seco a uno con lluvia: su coeficiente es la diferencia entre los dos tipos de día.

Las variables se eligen con las preguntas de la Clase 19: ¿las tendré al momento de predecir?, ¿aportan?, ¿repiten lo que dice otra? Por eso no usamos la sensación térmica: su correlación con la temperatura es de 0,99.

El modelo múltiple, en lenguaje de negocio

Variable	Coeficiente	Con lo demás igual…
intercepto	2070,77	
`temperatura_c`	152,56	cada grado más, unas 153 bicicletas más al día.
`humedad`	$-16{,}75$	cada punto más de humedad, unas 17 menos.
`viento`	$-51{,}17$	cada punto más de viento, unas 51 menos.
`es_2012`	1959,94	un día de 2012 tiene unas 1960 más que uno parecido de 2011.
`dia_laboral`	145,40	un día laboral tiene unas 145 más: poca diferencia.
`lluvia`	$-1239{,}71$	un día con lluvia o nieve, unas 1240 menos.

La temperatura bajó de 160 a 153

Parte de lo que el modelo simple le atribuía era, en realidad, del año o de la lluvia.

Grande no es importante

Los coeficientes dependen de las unidades: un punto de humedad no se compara con pasar de 2011 a 2012.

¿Valió la pena agregar variables?

Los tres modelos, con los mismos 147 días de prueba:

Modelo	MAE	RMSE	R^2
Línea base (siempre el promedio)	1712,0	2022,2	$-0{,}020$
Simple (temperatura)	1291,7	1545,9	0,404
Múltiple (6 variables)	**733,4**	**919,1**	**0,789**

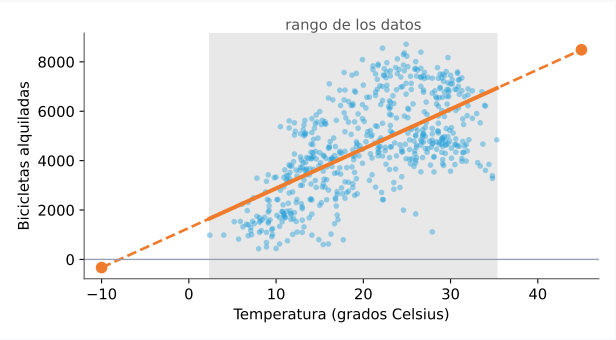
El mensaje para la gerencia

"Con el pronóstico del clima y el calendario, el error diario baja de unas 1700 bicicletas a unas 730: **menos de la mitad**."

Y una predicción concreta

Un día laboral de 2012, a 25 grados, humedad 60, viento 12: unas **6371** bicicletas sin lluvia y **5131** con lluvia, con un error típico de unas 730.

Extrapolar: predecir fuera de los datos



El modelo aprendió con días entre **2,4 y 35,3 grados** (zona gris). Fuera de ella, la recta sigue sin freno:

- A -10 grados predice -331 bicicletas: un número imposible.
- A 45 grados predice **8488**, aunque los datos muestran que con calor fuerte los alquileres bajan.

Regla

Usa el modelo solo dentro del rango de los datos con que aprendió, y para situaciones parecidas a las que vio.

Datos: Bike Sharing Dataset (Capital Bikeshare, Washington D. C.), UCI Machine Learning Repository, CC BY 4.0. Fanaee-T y Gama (2013).

Lo que el modelo no ve

Los días de prueba en que más se equivocó el modelo múltiple:

Fecha	Clima	Real	Predicho	Qué pasó
29 oct. 2012	Lluvia, 18 grados	22	2980	Llegó el huracán Sandy a la costa este de EE. UU.
29 jun. 2012	Despejado, 34,2 grados	5463	8006	Calor fuerte, que la recta no captura.

Eventos que no están en las columnas

Ningún dato del clima diario anticipa una ciudad cerrada por un huracán. Un modelo solo sabe lo que hay en sus variables.

No escondas estos casos

Explicarlos da confianza: muestra que sabes dónde funciona el modelo y dónde no. Van en tu presentación.

Otros tres riesgos

Riesgo	En nuestros datos	Qué hacer
Leer un coeficiente como causa	`es_2012` suma 1960 bicicletas. No es que el año cause alquileres: el uso del sistema creció de un año a otro.	Decir “se asocia con”, no “causa”, salvo que haya un experimento (Clase 19).
Variables que repiten lo mismo	Si agregas la sensación térmica, el coeficiente de la temperatura cae de 153 a 63 y el MAE apenas cambia (de 733,4 a 729,6).	Quitar una de las dos. Los coeficientes de variables redundantes no se pueden leer.
El negocio cambia	En 2012 el promedio diario fue de 5600 alquileres; en 2011, de 3406.	Volver a entrenar con datos recientes y vigilar el error mes a mes.

Antes de presentar un modelo de regresión

1. Miré el gráfico de dispersión antes de ajustar.
2. Medí con datos de **prueba**, no de entrenamiento.
3. Comparé con la **línea base**.
4. Reporto el **MAE** en unidades del negocio, junto al R^2.
5. Revisé los **residuos**: ¿tienen forma?
6. Expliqué cada coeficiente con “con lo demás igual”.
7. Dije el **rango** en que vale el modelo.
8. Expliqué los casos en que más se equivoca.

Una frase completa

“Con el pronóstico del clima y el calendario, podemos anticipar los alquileres del día con un error típico de unas 730 bicicletas. La lluvia los reduce en unas 1200. El modelo vale para días entre 2 y 35 grados y no anticipa eventos extraordinarios, como un huracán.”

La práctica: elige tu ruta

Ruta Python

Notebook `lab-regresion-lineal.ipynb`, en Google Colab. Usa pandas y scikit-learn, como en los Módulos 1 y 2.

Abrir en Colab

Ruta Orange

Guía `guia-orange-regresion-lineal.pdf`. Sin código: arrastras widgets y los conectas (Clase 19).

Descargar Orange

Las dos rutas tienen **los mismos nueve pasos**. Cada una reparte los días con su herramienta habitual, con la misma semilla: `train_test_split(test_size=0.2, random_state=42)` en Python y **Data Sampler** al 20 % con muestreo replicable en Orange. Eligen los mismos días, así que **las cifras salen idénticas**. Cada paso termina con una caja “Debes ver” para comprobar que vas bien.

1 Cargar y revisar los datos
2 Mirar la relación
3 Separar entrenamiento y prueba
4 La línea base
5 Regresión simple
6 Los residuos
7 Regresión múltiple
8 Predecir un día nuevo
9 Los límites del modelo

Producto esperado

Al final de la práctica entregas la **ficha en lenguaje de negocio** (está al final del notebook y de la guía):

1. ¿Qué decisión apoya el modelo?
2. ¿Cuánto mejora a la línea base? (MAE de la base y del modelo)
3. ¿Qué dos coeficientes le contarías a la gerencia, y cómo los dirías?
4. ¿En qué días se equivoca más, y por qué?
5. ¿Qué no debe hacerse con este modelo?

Si trabajas en pareja

Uno en Python y otro en Orange: comparen las cifras de cada paso. Si no coinciden, el error está en uno de los dos, y encontrarlo es parte del aprendizaje.

Cierre y próxima sesión

- La regresión lineal predice un número con una recta: $\hat{y} = b_0 + b_1 x$. Ajustarla es encontrar los coeficientes que hacen mínima la suma de los residuos al cuadrado.
- Cada coeficiente se dice en lenguaje de negocio: “por cada grado más, unas 160 bicicletas más”. En la múltiple, “con lo demás igual”.
- Se mide con datos de prueba y frente a la línea base: el **MAE** en unidades del negocio y el R^2 como orientación.
- Los residuos muestran lo que el modelo no ve: aquí, que el calor fuerte reduce los alquileres y que un huracán no está en los datos.
- Nunca extrapoles ni leas un coeficiente como causa.

Próxima sesión: Clase 21

Storytelling con datos: convertir hallazgos y modelos en una narrativa para una audiencia directiva.

Para seguir aprendiendo

Documentación

- scikit-learn: `LinearRegression`
- scikit-learn: medidas de error
- Orange: widget Linear Regression

Para profundizar

- An Introduction to Statistical Learning: libro gratuito, con un capítulo completo de regresión lineal y una edición con Python.

Los datos

- `bicicletas_diarias.csv`
- Bike Sharing Dataset (UCI), licencia CC BY 4.0
- Fanaee-T, H. y Gama, J. (2013). Event labeling combining ensemble detectors and background knowledge. Progress in Artificial Intelligence.

Las columnas se tradujeron al español y la temperatura, la humedad y el viento se devolvieron a su escala original.

¡Gracias!